Thinking with Video 中的工具使用：除放大与拆帧之外的视频操作工具谱系与研究进展

匿名作者

摘要

长视频推理的关键瓶颈在于：在上下文窗口与计算预算受限时，模型必须在“何时看、看哪里、看多少、看完如何核验”之间做出可追溯的取证决策；否则容易陷入一次性静态编码带来的信息瓶颈，并引发视觉幻觉与推理漂移。围绕“think-with-video”的工具使用（tool using）问题，本研究聚焦于除常见的局部放大（zooming）与拆帧/抽帧之外，视频推理系统中被反复工程化与复用的工具与调用机制，说明它们如何嵌入“规划—检索/定位—感知—验证/摘要—作答”的闭环，以及在不同任务上的可迁移边界与失效模式。

为系统化梳理工具类型，本文按功能将其归纳为四类：（1）时间轴证据获取工具，如片段检索、时间区间定位与裁剪；（2）证据核验与抗漂移工具，如验证器过滤、闭环一致性检查与证据奖励；（3）跨模态辅助工具，如 ASR/OCR、屏幕文本抽取，以及与外部文档/幻灯片的对齐；（4）对象级与运动证据工具，如跟踪、分割/掩膜传播、跨镜头重识别与运动表征。上述分类为本文综合多项工具增强系统与评测工作归纳所得，用于后续对比分析与边界讨论 [3, 5, 6, 7]。与此同时，模态路由、跨帧聚合/多数投票、自动化判题器等“调用策略与读出评测”机制通常跨越上述类别，既可作为检索/取证前的预算分配工具，也可作为证据读出与稳定性诊断工具。代表性系统表明，时间维度工具往往以“定位—裁剪—再定位”的多轮细化方式，把抽象子问题转化为可执行的检索、验证与摘要动作，从而用较少视觉 token 聚焦任务相关片段并提升可解释性与效率 [3, 4]；在交互式推理范式中，除放大与单帧冻结外，按段回看/重访关键时间窗（如 find-segment）被显式建模为原子操作，用以复核快速动作或关键瞬间并形成可审计的操作轨迹 [5]。在临床长视频等高风险场景，工具还会被约束为“粗到细”的层级取证接口（按时间窗裁剪获得密集观测、按时间戳取邻近帧做细粒度核验），并通过结构化轨迹格式与证据对齐奖励（如时间重叠/IoU 与时间戳对齐）将工具调用与可验证证据绑定，从而降低仅依赖文本链式推理造成的漂移风险 [6]。

综合来看，除 zooming 与拆帧之外，具有“可复用增量”的工具主要承担三类职责：第一，将长视频上的证据定位外部化为可调用算子（如 temporal grounding、clip retrieval/cropping、dense sampling 调度），使推理从“静态上下文”转为“按需取证”；第二，将证据可靠性外部化为可判别/可奖励的信号（如验证器过滤与证据奖励），以对抗幻觉与思维漂移；第三，将信息载体从纯视觉扩展到语音与屏幕文本等可索引模态，并通过路由策略决定“何时检索什么”。例如，多模态检索中的 LLM 路由器可基于查询意图在 ASR/OCR/视觉索引间选择性检索，将平均查询模态数从 3.0 降至 1.78，并在保持 Recall@5=60.9% 的同时实现约 41% 的计算开销降低，体现“工具选择”本身可作为独立推理算子 [7]；在讲座等结构化视频中，视频—幻灯片对齐可把外部文档编号转为时间锚点，通过语音转写、OCR 与图像特征融合及动态规划序列约束，实现平均对齐准确率 0.82、相对 SIFT 基线显著提升且运行时间约快 11 倍，为后续检索与证据定位提供可复用索引结构 [8]；在“以视频生成参与推理”的路径上，跨帧抽样与多数投票（Major Frame）相较仅取末帧可提升判定稳定

性（如平均正确率 40.2% 对比 33.4%），以及“best frame”选择与 LLM-as-a-Judge 等读出/评测工具，共同构成将视频输出转化为可验证结论的工具链 [1]。

同时，工具并非越多越好：其效用对任务与训练设定高度敏感，并可能带来负迁移。以时序定位为例，引入 clip caption 或 clip QA 工具在某些设置下不仅无益，甚至导致 mIoU 明显下降，而视频裁剪在经验上更能降低幻觉，提示工具价值取决于与任务目标、奖励与调用策略的耦合方式 [2]；多轮定位的强化学习还可能出现基于 IoU 的 reward hacking，需要引入惩罚感知奖励以抑制“猜测式定位”并稳定学习 [4]。在空间层面，精确区域定位（尤其包含文本/数字的区域）被指出是交互式操作范式的主要瓶颈之一 [5]；动态视频 OCR 在小文本、运动与模糊条件下性能显著退化、易漏检短暂文本并产生字符幻觉，表明“读屏/文本取证”需要与更强的时空定位与帧选择机制结合 [9]。此外，证据奖励与抗漂移训练虽能在多个公开视频推理基准上提升稳健性，但其结论仍受输入视频长度与帧采样完备性制约，对“极长且关键信息稀疏”的场景外推仍是开放问题 [10]。总体而言，think-with-video 的工具使用可被理解为一组面向证据获取、证据核验与资源调度的可组合算子体系，其有效边界主要由任务可定位性、标注/奖励的可验证性以及跨模态索引质量共同决定 [3, 6, 7]。

关键词： 长视频推理；工具调用；时间定位；证据核验；多模态检索；对象跟踪

1 引言：研究背景、问题定义与贡献

长视频理解与推理（long video understanding/reasoning）正成为多模态智能体走向真实世界的重要门槛：一方面，视频天然包含跨时间展开的事件链、对象交互与因果关系，信息量随时长线性增长；另一方面，当前主流视频大模型在推理时往往受到上下文窗口与视觉 token 预算的双重约束，只能对视频进行一次性编码并在“静态视觉上下文”之上完成文本推理。Video-CoM 将这种范式概括为“think about videos”：视频被压缩成一次性输入，后续推理完全发生在文本空间，导致语义瓶颈（semantic bottleneck）——模型无法像人一样暂停、回看、改变注意区域或核验关键证据，从而在细粒度时空推理任务上容易表现为“浅层看图式”的捷径策略或直接幻觉 [5]。

围绕这一矛盾，近一年提出的“think with video(s)”/交互式视频推理范式，将视频不再视为被动上下文，而是可被反复访问与操控的“认知工作台（cognitive workspace）”。VideoExplorer 的表述强调：推理应是一个围绕“按需时间上下文（on-demand temporal context）”展开的动态过程，系统会针对子任务提出可伸缩的感知查询，并通过规划、时间定位与可伸缩视频感知协同完成证据获取与答案生成 [3]。Video-Thinker 则进一步把“工具增强的视频推理”形式化为序列决策过程：智能体在“中间思考—动作选择（工具调用）—获得新视觉观测”的闭环中学习何时、如何调用视频工具，以实现由粗到细的取证行为，而不是依赖固定的帧采样启发式 [11]。

如果将“工具使用（tool using）”视作该范式的核心差异点，那么长视频推理面临的关键挑战就不再仅是“如何设计更大/更强的编码器”，而是“如何在推理过程中组织证据获取与核验”。一类挑战来自评测与任务设计：GLIMPSE 指出大量既有视频基准仍呈现“类图像化”倾向，模型往往扫描少数关键帧即可作答，无法检验其是否具备真正的跨帧综合推理能力；为此其构建的题目被要求必须观看全视频并基于完整上下文推理，人类专家准确率可达 94.82%，而当前最佳模型（GPT-o3）仅 66.43%，反映出现阶段模型在深度视频推理上的显著差距 [12]。另一类挑战来自推理可靠性：当我们引入更长的推理链与更复杂的中间表述时，链式思维（CoT）在视频任务上可能出现“视觉思维漂移（visual thinking drift）”，即产生冗长却误导的内部独白、编造视觉细节甚至覆盖正确直觉；为对抗漂移，研究开始将“是否可由视觉证据验证”显式纳入训练目标，例如用 Visual Evidence Reward（VER）奖励那些可核验地扎根于视觉证据的推理轨迹 [10]。

在上述背景下，“think with video”研究线逐渐从单纯的模型结构与训练数据规模竞争，转向以工具为中心的系统化改造：用外部/可执行的操作把“看视频”的过程拆成可调用模块，再用规

划、路由与强化学习把这些模块编排成闭环。已有工作中，最直观、最常被讨论的工具是空间层面的 zooming（放大/裁剪）以及时间层面的拆帧/抽帧（frame sampling）。然而，无论是人类观看视频的行为，还是近期系统在长视频检索、证据定位与核验方面的探索，都显示“工具”远不止于此：例如 Video-CoM 在原子操作层面除 spatial-zoom 外，还将时间回看显式工具化为 find-segment（按段检索短时间窗以重访关键时刻）与 find-frame（冻结关键帧以获取高分辨率证据），并把多步操作组织成可解释的交互轨迹 τ[5]；VideoExplorer 的时间定位模块则把“构造—检索—验证—总结”视作可执行动作集合，通过离线片段嵌入库与在线匹配实现对长视频的按需重访，并用验证器过滤无关片段以缓解幻觉 [3]。此外，工具化不一定意味着对原视频做更激进的编辑；也可以是“信息预算调度”与“索引路由”这样的高层工具：如 ModaRoute 用 LLM 路由器在 ASR/OCR/视觉三类索引间做选择性查询，报告在平均仅查询 1.78 个模态（相对穷举 3.0 模态）时实现约 41% 的计算开销降低并保持 Recall@5=60.9% 的检索效果，体现了“何时搜什么（when to search what）”本身可被工具化与学习化 [7]。同样，在长视频问答中，Moment Sampling 用文本-视频 moment retrieval 模型（QD-DETR）引导帧选择，并引入模糊度质量分（拉普拉斯方差）、均匀性分散约束与聚类去冗余等决策组件，将“抽帧”从固定间隔策略推进到可复用的“检索式采样工具链”[13]。

因此，本文聚焦的问题可以表述为：在“think with video(s)”范式下，除 zooming 与拆帧/抽帧这两类最直观操作外，人类与研究社区究竟还发明了哪些可复用的视频推理工具？这些工具如何被封装为可调用接口（tool call），并与规划、检索、核验、摘要等机制组成稳定的调用闭环？与把能力“内化”到模型结构或端到端训练不同，工具视角强调两点：其一，工具往往对应明确的外部执行语义与可观测反馈（如检索返回片段、裁剪返回高分辨率局部、验证返回通过/拒绝），更易形成可解释、可度量的中间证据；其二，工具选择与调用策略本身可以被学习（如 RL 学习 when-to-look/where-to-look），也可以通过路由与奖励设计显式控制其效率—保真折中，从而在长视频场景更具工程可扩展性 [11, 7]。

围绕上述研究问题，本文的预期贡献在于：第一，以“工具谱系（tool taxonomy）”的视角系统梳理长视频推理中已被提出或隐式使用的工具类别，覆盖时间维度的检索/定位/裁剪、证据核验与抗幻觉机制、跨模态信息抽取（ASR/OCR 等）、对象与运动证据工具（跟踪/分割/运动表征）以及工具调用策略与训练对齐等方面，并强调它们相对“拆帧/放大”的增量价值与适用边界。第二，从调用机制层面抽象典型系统的共同闭环：规划器如何提出子问题与信息需求，时间定位/检索模块如何将抽象需求转化为可执行动作并返回经验证的证据，以及可伸缩感知如何在有限窗口下进行粗到细的采样调度 [3, 5]。第三，结合最新基准与分析工作讨论工具视角下的评测要点与可靠性风险：例如 GLIMPSE 对“只扫少数帧”的评测捷径进行约束 [12]，以及 VER 针对“推理链漂移”将证据可验证性纳入奖励信号 [10]，为后续工具设计与评价提供可操作的参考。

本文首先界定“think about videos”与“think with videos”的差异，并明确对工具、工具调用与视频操作的讨论边界；随后综述相关工作并抽象典型的工具调用闭环，进而提出工具谱系的分类维度与对比框架；最后围绕时间维度工具、证据核验与摘要工具、跨模态辅助工具、对象级与运动证据工具，以及工具调用策略与训练对齐方法展开讨论，并在此基础上归纳评测要点、可靠性风险与开放问题。

2 术语与范围：从“think about videos”到“think with videos”

本文讨论的“think with video / thinking-with-videos”并非泛指“模型能回答视频问题”，而是强调推理过程与视觉证据获取过程被耦合为可反复交互的闭环：模型在推理中可以回看、聚焦、验证并据此更新后续推理步骤，而不是将视频一次性编码为静态上下文后，后续推理完全在文本空间展开。Video-CoM 将后者概括为多数方法仍在“think about videos”的被动范式：视频被编码后，

推理在文本中展开，形成“semantic bottleneck”，使模型无法“rewatch, refocus, or verify evidence”，在需要细粒度时空理解的任务上更易产生浅层推理与幻觉；相对地，“think with videos”把视频视作动态的“cognitive workspace”，通过迭代视觉动作来收集与精炼证据。[5]

在这一范式中，“tool（工具）”指一种可被显式调用的、对原始视频或其派生表示执行的操作模块，它在推理中充当“按需感知接口”，将“看哪里/看多久/看多细”从端到端编码中外部化为可控动作。Video-Thinker 将工具增强的视频推理形式化为序列决策过程：智能体在“生成中间思考（intermediate thoughts）”与“从工具集合中选择动作”之间交替，以获得新的视觉观测，并通过强化学习学会何时以及如何调用这些视频工具。[11] 因此，这里所说的工具并不限于传统意义上的视觉算子（如检测、分割），也包括更“编辑式/交互式”的视频操作，例如时间跳转（seek）、片段截取（trim/extract sub-clip）、区域裁剪放大（zoom/crop）等轻量操作。它们的共同特点是：一次调用会返回新的、任务相关的视觉上下文，从而改变后续推理的输入条件。[11]

“tool call（工具调用）”指一次结构化的工具请求，以及其执行结果进入推理上下文的过程。工具调用的结构化表达通常是实现稳定闭环的关键工程约束：例如 VITAL 为稳定“thinking 与 tool calling”的交替，要求模型以特定的标签与字段格式输出（例如用 `<think>`、`<tool call>`、`<answer>` 等区块，并在 tool call 中以 JSON 样式给出 `name` 与 `arguments`），并引入基于规则的格式奖励来强化该约束。[2] 这种严格格式把“推理文本”与“可执行动作”解耦，便于复现工具序列、做消融分析与进行可解释的证据链追踪。

本文进一步采用“manipulation（操作/操控）”来指代可被模型选择的原子级视频动作集合，强调其可组合性与轨迹结构。Video-CoM 将交互式推理建模为“Chain of Manipulations（CoM）”，每一步从若干原子操作中选择其一，并把多轮过程形式化为轨迹 $\tau = \{(T_1, V_1, m_1), \ldots, (T_N, V_N, m_N)\}$，其中 T_i 为当轮中间推理文本，m_i 为当轮操作，V_i 为该操作得到并反馈的新视觉上下文。[5] 在其实现中，原子操作包括 `find-segment`（按段索引取回短时间窗以重访/回看关键片段）、`find-frame`（定位单帧以获得高分辨率静态证据）与 `spatial-zoom`（对局部区域裁剪放大以检查细节）。[5] 这种“操作”概念强调：工具使用并不等价于“多抽几帧”，而是以可执行动作将注意力、时间窗口与空间分辨率在推理过程中显式重分配。

“temporal grounding（时间定位/时间区间定位）”在本文中特指：把自然语言问题或子问题映射为视频时间轴上的一个或多个区间（或段索引），并将其作为后续感知与回答的证据载体。Video-Explorer 将“thinking with video”描述为面向“on-demand temporal context”的动态推理过程：规划器将复杂问题分解为子问题，时间定位模块自适应地局部化相关时间跨度，随后感知模块在这些时间跨度内以可伸缩粒度进行理解，从而避免对全片段进行蛮力式下采样或静态预处理。[3] 与此相伴的“on-demand perception（按需感知）”指模型并不固定以均匀采样覆盖整段视频，而是由任务驱动地产生可伸缩的感知查询；在 VideoExplorer 的叙述中，不同任务会触发不同采样粒度：细粒度问题在定位到的时间窗内进行更密集采样，而全局性问题可覆盖更宽时间窗并采用更粗采样，以在上下文窗口受限下实现“scalability–fidelity”的折中。[3]

为更清楚地区分“工具调用”与“被动编码”，本文用“交互式感知—推理闭环”指代一类系统范式：推理链条中至少包含一次显式的视频定位/裁剪/采样调度动作，并在得到新观测后继续推理与再决策。VideoTemp-o3 将 thinking-with-videos 直接任务化为“localize-crop-answer”过程，并强调在长视频中可通过迭代调用工具（例如视频裁剪与密集采样）来弥补均匀采样常遗漏关键证据的缺陷；其框架支持多轮时间定位细化（multi-turn grounding refinement），直到收集到足够证据再作答。[4] 这一表述对应本文的关键边界：我们关注“推理过程中能反复定位与取证”的机制，而不是仅在输入端做一次性预处理（如离线抽帧、全局特征池化）后再进行单轮文本推理。

除“获取证据”的工具外，本文也将“证据核验/对齐”视为 think-with-video 工具链中同等重要的组成部分，因为长视频推理常出现“推理漂移”与视觉幻觉。VideoExplorer 在时间定位模块中

引入验证环节：用 VLM 作为 verifier 评估检索片段是否相关，丢弃无关结果并只把通过验证的片段返回给高层规划器，从而减轻无关上下文引发的幻觉风险。[3] When Thinking Drifts 则从链式思维在视频推理中可能“生成冗长但误导性的内心独白、产生幻觉细节并覆盖正确直觉”出发，将该现象命名为 visual thinking drift，并提出 Visual Evidence Reward（VER）用强化学习显式奖励“可被视觉证据验证支撑”的推理轨迹；其关键设定之一是将“visual evidence”定义为问题相关（question-dependent），并在训练阶段利用强 MLLM 生成支撑性视觉观察列表，使策略模型的推理更贴近可验证证据。[10] 在本文术语体系中，这类机制被归入“evidential grounding（证据化落地）”：不仅要回答问题，还要让推理链中的关键断言能对应到可检查的视觉事实，从而使工具调用序列具备可审计性。

研究范围方面，本文聚焦于“长视频推理（long video reasoning）/长时程视频理解”语境下的工具使用：一是面向长时长带来的计算预算与上下文窗口限制，工具用于实现时间定位、裁剪、密集采样与证据重访；二是面向证据稀疏与误检索风险，工具用于验证、过滤与证据对齐；三是面向可解释性与可复现分析，工具调用需要以结构化接口与轨迹形式呈现。[3, 4, 11] 与此相对，GLIMPSE 对“thinking with video”的评测定义强调：问题必须要求观看整个视频并在全视频上下文上推理，不能通过扫描少数关键帧或依赖文本捷径作答；这类基准为诊断“是否真正使用全视频证据”提供了参照——如果某种所谓“工具使用”最终仍退化为“glimpse 少数帧即可答”，则难以支撑其“think with video”的主张。[12] 因而，本文不把“视频到文本的一次性描述/摘要然后用文本推理”视为 think-with-video 的充分条件；同样也不把“仅增加输入帧数”当作工具化推理的替代。

最后，本文讨论的“工具”限定为能被系统显式调用并改变后续感知输入的模块或步骤（例如时间定位、裁剪、密集采样、片段检索与验证、以及面向证据的奖励/核验），而不扩展到所有模型内部的隐式能力（例如仅靠提示词引导注意力但不产生可执行动作的做法）。这种限定使不同工作可在统一口径下比较其工具集合、调用策略与可解释的证据链条，并为后续章节梳理“除 zooming、拆帧之外，视频推理中还存在哪些可复用工具”提供清晰边界。[2, 5, 11]

3 相关工作综述与研究脉络

围绕“think with video”的工具使用（tool using）问题，相关研究大致可沿两条主线展开：一条是以 Video-LLM 为代表的“端到端视频编码—语言推理”路线，关注如何在长视频与时序依赖下提升表示能力、训练对齐与评测覆盖；另一条是近年来兴起的 agentic/工具增强范式，将视频理解过程显式外部化为可调用的操作或模块，使模型在推理过程中能够“再观看/再定位/再取证”，从而突破一次性编码带来的语义瓶颈并提升证据可追溯性。

在视频—语言模型与长视频推理方向，早期与主流 Video-LLM 工作通常采用“视频编码器—跨模态投影—LLM”的三段式架构，并通过多阶段训练（大规模视频—文本对预训练、再进行指令微调）将视频理解能力对齐到语言空间，相关综述对这一技术栈、数据集与基准谱系已有系统梳理 [14]。例如，Video-LLaMA 将音频与视觉信号与指令微调结合，代表了“端到端对齐到语言空间”的通用基线之一，可作为后文讨论工具增强范式的对照 [15]。在长视频情境下，视频相较图像的挑战集中在时间动态、长程依赖与多模态对齐带来的 token 与计算开销，因而形成了均匀采样、片段级聚合、时序注意力以及引入外部记忆等多种处理路径 [14]。

然而，GLIMPSE 的分析指出，许多“类图像化”的视频基准可以被少量关键帧“扫一眼”式解决，从评测层面削弱了对深时序推理的辨别力；其构建的 3,269 段视频与 4,342+ 题、11 类任务的视觉中心基准，要求模型观看完整视频并进行跨帧推理，并在人工评测与当前模型之间形成显著差距，揭示了长视频推理在“信息整合与选择”维度仍存在结构性短板 [12]。这类发现进一步说明：单纯增加输入帧数并不能线性提升效果，帧数超过阈值后收益递减甚至下降的现象，提示“如何决

定看什么、何时看、看多细”正在成为比“看多少帧”更核心的瓶颈 [12]。此外，也有工作从提示与启发式角度探索如何让视频—语言基础模型在特定领域的视频问答中更稳健地组织作答步骤与信息使用，这类“提示/策略”可视为后文所讨论“软工具”边界的一个来源 [16]。

在 agentic/工具增强框架方面，Video-CoM 将问题明确归因于“视频被一次性编码后推理完全在文本空间展开”的被动范式，指出其造成模型无法回看、聚焦与验证证据的语义瓶颈，并提出交互式视频推理：把视频当作可操作的认知工作台，通过“Chain of Manipulations”在多轮交互中执行视觉动作以收集并精炼证据 [5]。该框架将工具化操作收敛为三类原子操作：

- *find-segment*（按段回看短时间窗以重访关键时刻）；
- *find-frame*（隔离单帧高分辨率证据）；
- *spatial-zoom*（局部裁剪放大以检查细节）。

并将推理过程形式化为包含每步文本与操作的轨迹，从而为“工具调用如何被组织成可解释的多步链”提供了标准化表述 [5]。在训练上，Video-CoM 进一步提出对每一步操作正确性进行度量与奖励的 RA-GRPO，以缓解仅用最终答案监督导致的路径漂移，并在强调操作能力的基准上获得明显提升；其强化学习样本规模仅 3K，表明工具链与逐步奖励可在较小 RL 数据下促成有效的交互策略学习 [5]。

与“工具增强但强调何时调用”的路线相呼应，Video-Thinker 将工具增强视频推理建模为序列决策过程，智能体在“中间思考”与“工具动作选择”之间交替，工具集合涵盖时间 seek、片段 trim/extract 以及空间 zoom/crop 等轻量级视频操作，并通过强化学习学习由粗到细的取证策略，同时以工具调用开销惩罚平衡性能与效率 [11]。其消融显示，去除时间维度工具（temporal seeking、clip extraction）会显著降性能，暗示除空间放大之外，“时间导航—片段截取”的工具对长程推理具有不可替代的贡献 [11]。在更强调“时间定位与问答统一”的设计中，VideoTemp-o3 将 thinking-with-videos 形式化为 *localize-crop-answer* 过程，支持按需裁剪与多轮定位细化；其数据构造采用强模型生成候选时间段并裁剪，再通过闭环一致性验证筛选样本，并对长视频（>3min）进一步启用多轮 refinement 生成多工具调用轨迹，体现了工具调用次数与视频时长/任务难度的耦合关系 [4]。这些工作共同推动了一个研究脉络：工具不再仅是“更强的视觉编码器”，而是推理链中的可执行操作与决策对象，学习目标从“答对”扩展为“以怎样的交互轨迹答对”。

在视频检索与时间定位研究线中，VideoExplorer 更系统地把“规划—时间定位—可伸缩感知”整合为统一范式：规划器分解复杂任务并提出子问题，时间定位器在离线分段的多模态嵌入库上进行在线匹配，并把检索过程与主推理链解耦，支持构造、检索、验证、总结等动作并将经验证片段返回规划器 [3]。其进一步强调不同任务对应不同时间粒度需求：对细粒度问题在定位到的时间窗口内进行密采样，对全局问题覆盖更大时间区间并采用粗采样，以在上下文窗口受限下平衡可扩展性与细节保真 [3]。该框架以“更少视觉 token 但更好性能”的证据说明按需检索与预算调度的有效性，并指出相较若干检索增强 agent 框架，其时间定位精度更高，核心原因在于分步推理与片段证据的对齐 [3]。与之相对，VITAL 这类工具增强框架也从消融角度强调“工具选择并非越多越好”：在时序定位任务中，加入 clip caption 或 clip QA 工具不仅无益甚至会造成 mIoU 显著下降，而 video clipping 在经验上更能降低幻觉，提示工具与任务/评测设定存在强耦合，需要系统化的工具有效性分析与组合策略 [2]。

围绕视频采样与效率优化，除传统均匀抽帧外，越来越多工作把“关键时刻/片段选择”视为可独立模块甚至外部工具：Moment Sampling 以通用文本到视频的 moment retrieval 模型指导帧采样，提出与下游 VideoLLM 解耦、无需再训练的 query-aware 选帧方式，先用 QD-DETR 预测相关时间片段并将相关性分数转为帧级得分，再结合高斯平滑、质量分（以拉普拉斯方差检测模糊）、均

匀性分散约束与特征聚类去冗余，最终用贪心策略选帧 [13]。这种“检索信号 → 采样决策”的工具链与 GLIMPSE 所揭示的“帧数增加但收益下降”现象形成呼应：长视频推理的关键不在于输入更多帧，而在于用更强的路由/筛选机制把感知预算聚焦到与问题相关的证据上 [12, 13]。

与采样效率互补的是“检索什么模态”的路由问题。ModaRoute 将多模态视频检索拆解为对 ASR、OCR 与视觉索引的选择性查询，并用 LLM 对查询意图进行分析以动态选择最相关模态，再对被选模态并行检索并融合排序；其在评测中以平均每次仅查询 1.78 个模态（对比穷举 3.0 模态）实现计算开销显著降低且保持较高召回，揭示了工具增强不仅发生在视频剪辑/裁剪层，也可发生在检索层的“信息源路由”层 [7]。该工作同时指出 dense captions 尽管可获得更高召回，但离线处理代价高且对含场景文本而 ASR 未覆盖的片段存在遗漏，为后续将 OCR/字幕等作为显式工具并与路由策略耦合提供了量化动机 [7]。

在“证据可靠性与推理漂移”相关研究中，When Thinking Drifts 系统分析了将 CoT 直接用于视频推理可能导致性能下降与“visual thinking drift”，并提出 Visual Evidence Reward（VER）在强化学习中显式奖励“可验证地扎根于视觉证据”的推理轨迹；其训练阶段借助强 MLLM 生成问题相关视觉证据，但推理阶段不依赖外部模型，从而将工具（教师/证据生成器）限定在训练期使用以降低测试期开销与反馈环风险 [10]。该工作同时指出失败模式之一来自不完整帧采样导致关键信息缺失，进一步说明“采样/定位工具”与“证据对齐/验证工具”在长视频推理中是相互制约的共同体 [10]。

最后，视频生成式推理范式为 think-with-video 的研究脉络提供了另一种路径：与“通过工具取证后作答”的范式不同，视频生成式推理主张将推理过程外显为可生成、可检查的中间视频，从而把“想象/演算”置于视频表征空间中，以期获得更强的多模态推理与可验证性 [1, 17]。在这一谱系里，工具的含义可能从“检索与裁剪”等外部操作扩展为“生成—对齐—对比”的内部演算机制，并与现有以检索/定位为中心的工具链形成互补：前者更像在视频空间中构造可检验的中间变量，后者更像在真实视频证据上做按需的取样与验证。

综合来看，现有综述多以“模型架构—训练数据—任务基准”的视角组织 Video-LLM 研究版图 [14]。而近期 think-with-video 相关工作则把注意力转向推理过程本身的可操作性：通过规划、时间定位、裁剪、密/粗采样切换、模态路由与证据验证等模块，将“看视频”重构为可学习的工具调用序列 [3, 4, 5, 11, 13, 7, 10]。在此背景下，引入“工具谱系（tool lineage）”视角具有必要性：以人类观看视频时可执行的操作为原型，对齐到现有系统中的可调用工具、接口形态与训练对齐方法，并分析工具之间的组合关系（如检索—验证—再检索、由粗到细、预算调度）及其在不同任务与评测设定下的增量价值，从而更具体地解释为何某些工具有效、某些工具在特定设定下反而有害 [2, 3, 12, 13, 7]。

4 典型 think-with-video 框架中的工具调用闭环

在“think-with-video”范式中，工具并非附着在模型外部的可选加速项，而是把“看视频”这一感知过程重新组织为可被语言推理显式调度的动作序列：模型（或多智能体系统）先提出下一步的信息需求，再通过工具在长视频中定位可疑证据段，随后以合适的时间/空间粒度重新感知并产出可核验的观察，必要时再执行验证、摘要或二次检索，最终在证据充分时给出答案。这种“规划—定位/检索—感知—验证/摘要—作答”的闭环之所以在长视频场景里变得关键，一方面来自上下文窗口和计算预算对“全量编码 + 一次性推理”的限制，另一方面也来自视频推理中幻觉与“推理漂移”风险：若缺少证据回看与核验机制，模型容易生成冗长但缺乏证据支撑的推理文本，甚至覆盖原本正确的直觉判断，从而偏离真实视觉证据 [10]。

以 VideoExplorer 为代表的一类系统把闭环拆成明确的角色分工：规划器（planner）负责问题分析、子问题分解、提出迭代信息需求并串联最终作答；时间定位器（temporal grounder）将“抽

象的子问题”转化为检索与执行动作；感知模块根据规划需求在指定时间区间上做可伸缩的采样与理解 [3]。该框架的关键在于把“定位/检索”从主推理链中解耦：离线阶段将视频切分为 clips 并存入多模态嵌入库，在线阶段 grounder 既支持文本查询也支持多模态查询匹配候选片段，并进一步把检索过程组织为“构造—检索—验证—摘要”等动作序列，最后只把经验证的片段作为低层规划结果回传给 planner[3]。在这一闭环里，“验证”不是事后评测，而是定位环节的内生步骤：grounder 采用 VLM 充当 verifier 过滤无关片段，借此降低无关上下文引发的幻觉，使 planner 可以把推理预算集中在高层任务分解与证据对齐上 [3]。感知端同样被工具化为“时间粒度可控”的操作：对于细粒度问题，在被定位出的短时间窗内密集采样以提高保真；对于全局性问题，则以更粗的采样覆盖更长区间以保证可扩展性，这形成了以任务为条件的“感知预算调度”接口 [3]。

另一条代表性路线以 Video-CoM 的“Chain of Manipulations (CoM)”为核心，把闭环具体化为多轮交互轨迹 $\tau = \{(T_1, V_1, m_1), \ldots, (T_N, V_N, m_N)\}$：每一轮在文本推理 T_i 之后选择一个原子操作 m_i，执行后得到新的视频视图 V_{i+1} 再继续推理，直至输出最终答案 [5]。CoM 的重要贡献是把“工具空间”压缩为少量可组合、可监督的原子操作集合，使闭环的接口足够清晰：模型每步只能在 find-segment（按段回看短时间窗）、find-frame（从原视频中隔离出单帧高分辨率证据）、spatial-zoom（裁剪并放大局部区域）三者中选择其一，以主动收集局部化的时空证据 [5]。为了让“定位”动作在模型内可执行，Video-CoM 还将原视频预分段为等长区间，并把 segment/frame 的索引直接叠加在帧上，工具调用等价于在一个离散化的时间—空间坐标系中做可解释的导航与放大 [5]。在此闭环下，工具的角色不仅是提供新像素，更是把“回看、暂停、聚焦”等人类观看动作转译为可学习的离散决策序列，从而使中间步骤可以被标注、被奖励、被消融分析。

VideoTemp-o3 则将闭环抽象为更紧凑的“localize-crop-answer”过程，并强调多轮 refinement：模型支持按需 grounding 与 cropping，并允许在证据不足时多轮细化定位直到获得足够证据再作答 [4]。其数据构建进一步把“验证”显式纳入闭环：首先由 Gemini-2.5-Pro 预测候选时间片段并裁剪，然后把裁剪片段与原问题一起输入模型，并明确约束模型只能基于该片段回答；随后进行闭环一致性验证（closed-loop consistency verification），只有当最终答案与 ground-truth 保持一致时样本才被保留，形成多轮、单工具调用训练数据 [4]。对于长视频（$> 3\,\text{min}$），系统允许额外一轮 refinement 才保留为 multi-tool-call 训练数据，从而把“第一次定位失败—再次定位—再裁剪”的真实交互轨迹纳入监督分布 [4]。在强化学习阶段，VideoTemp-o3 还指出仅用 IoU 作为定位奖励会诱发 reward hacking（模型任意定位以刷分），因此引入带惩罚项的 IoU 奖励以抑制低质量定位并促进更稳定的多轮细化学习，这实质上把“验证/约束”机制做成了可优化的训练接口 [4]。

与上述“闭环即交互推理轨迹”的系统设计相配套，另一类工作更强调工具接口与输出格式的工程化稳定性。VITAL 在训练中通过严格的结构化输出约束与格式奖励来稳定“思考—工具调用—继续思考—作答”的 rollouts：例如将模型输出格式提示为 `...<answer>...</answer>`，并对轨迹施加规则化的格式奖励 $R_{\text{format}}(\tau)$，以减少工具调用协议被破坏导致的训练不稳定 [2]。在工具层面，VITAL 的消融结果提示“工具并非越多越好”：在时序定位任务上加入 clip caption 或 clip QA 工具不仅无益，反而会显著拉低 mIoU；相比之下，video clipping（按时间窗裁剪并重新感知）在经验上更能降低幻觉 [2]。这类发现说明闭环中的“感知工具”需要与任务目标和训练信号匹配，否则会把噪声或无关信息引入证据链，反向破坏定位与核验。

在临床长视频场景，MedScope 将闭环组织为交错式视觉链式思维（VCoT）：每轮先输出文本理据，再决定是否调用工具获取证据并将观察结果反馈到下一轮推理，并通过强制的结构化接口 `<think>`（文本理据）、`<tool_call>`（视觉理据/动作）、`<tool_response>`（工具观测）、`<answer>`（终止预测）把推理与取证分离，从而使轨迹既可学习也可审计 [6]。其工具箱刻意保持“轻量但层级化”：`crop_video` 输入视频与时间窗，返回该窗内密集采样的帧序列用于局部证据搜集；`get_frame` 输入时间戳，返回邻近三帧用于细粒度核验 [6]。也即，“定位/检索”主要依赖时间窗裁剪，而“验

证/复核”更多由近邻帧抽取完成，两者共同实现从粗到细的证据获取闭环，符合临床推理中“先全局扫视再局部回看”的工作流假设 [6]。

如果把上述系统视为“闭环的结构化实现”，那么 Video-Thinker 提供了“闭环的学习化实现”视角：它将工具增强的视频推理形式化为序列决策过程，智能体在生成中间想法与从工具集合中选择动作（如时间 seek、clip extraction、区域 zooming/cropping）之间交替，以获得新的视觉观测，并通过强化学习学习何时、如何调用工具，从而形成由粗到细的证据获取策略 [11]。该框架同时把“效率约束”纳入闭环成本模型：训练奖励除了正确性，还包含对过度工具调用的惩罚，以在性能与交互开销之间做折中 [11]。这使工具接口不再只是可执行操作的集合，而成为可被策略优化的动作空间；闭环是否收敛到“少而关键的证据调用”，取决于奖励塑形能否同时惩罚冗余回看并鼓励命中关键时刻。

值得注意的是，闭环中“定位/检索”并不局限于时间段检索或裁剪。ModaRoute 在多模态视频检索中把“选择检索哪些模态索引”本身工具化为路由决策：LLM 路由器根据查询意图预测信息最可能位于 ASR（语音）、OCR（屏幕文本）或视觉索引之中，只对被选模态并行检索并做排序融合，从而把“何时搜什么”变成可插拔的工具调用前置环节 [7]。其结果显示，相比对三种模态的穷举检索（平均 3.0 模态/查询），路由后平均只需查询 1.78 个模态即可实现约 41% 的计算开销降低，同时保持 Recall@5 = 60.9% 的检索效果 [7]。当此类路由器被并入 think-with-video 的整体闭环时，它提供了一个更上游的“检索预算分配”接口：在进入视频裁剪/密采样等高成本感知工具前，先用语言理解估计最可能的证据通道，从而改变后续闭环的成本结构与误差模式。

综合这些代表性方法可以看到，典型 think-with-video 的工具调用闭环并非固定模板，而是围绕同一条因果链反复重排接口：规划器或策略负责提出信息需求并决定是否继续取证；定位/检索模块把需求落地为可执行的时间窗、时间戳、片段索引或模态索引选择；感知模块在被约束的证据范围内做密集/高分辨率的重新观测；验证与摘要模块则负责过滤无关检索结果、做闭环一致性检查或生成可供后续推理引用的结构化证据；最终作答模块在证据充分时终止交互并输出结论 [3, 4, 5, 6]。其中，“验证/摘要”既可能以推理时的 verifier/一致性检查出现（如检索结果过滤、闭环一致性验证），也可能以训练时的奖励与数据筛选出现（如格式奖励、证据对齐奖励、对 reward hacking 的惩罚），两者共同决定了闭环能否稳定地产生可追溯的证据链并避免推理漂移 [2, 4, 3]。

5 工具谱系的分类维度与对比框架

围绕“think with video”的工具使用（tool using），若只用“是否能放大（zoom）、是否能拆帧/抽帧”来划分工具，往往会把大量关键差异（例如：工具是否显式对齐证据、是否支持反复细化定位、是否依赖离线索引、是否通过路由策略决定调用对象等）压缩为同一种“多看几眼”的直觉。更可比的做法是：用一组稳定的分类维度描述不同论文/系统的工具箱，并在每个维度下记录可观察要素——工具输入/输出是否可执行、与推理链耦合在何处、是否支持多轮调用与粒度调整、是否存在证据可靠性闭环等——从而将差异落实到可对照的接口与流程层。

首先可用“作用轴”来区分工具主要在时间维度还是空间维度上改变可见证据。时间维度工具的共同点是把连续视频压缩为可被精确复访的时间片段，并允许在时间轴上做“搜索—重访—再搜索”的迭代，而不仅是一次性均匀采样。VideoExplorer 将这一思路明确为“动态 temporal grounding + temporal-scalable perception”的统一范式：规划器分解子问题，时间定位器把抽象信息需求变成对候选片段的检索、验证、总结等动作，并把通过验证的时间片段返还给规划器；随后感知模块再根据任务要求在该区间内做密采样或粗采样，实现时间粒度的动态调整 [3]。Video-CoM 则把时间维度工具以原子操作形式显式化：除空间放大（zoom）外，提供 find-segment（按段回看短 clip）与 find-frame（定位单帧），并将多步操作组织为一条可解释的交互轨迹 $\tau = \{(T_i, V_i, m_i)\}_{i=1}^{N}$；这里“工

具”不仅是取证动作本身，也包括把索引（segment/frame ID）叠加到画面上以便精确调用的工程化设计 [5]。与之相比，VideoTemp-o3 以“localize-crop-answer”概括工具链：先定位时间区间，再裁剪该区间并在裁剪后执行更密的采样取证，且允许多轮 refinement 直到证据充分 [4]。这些工作共同表明，时间轴工具的关键增量不在“抽几帧”，而在“把时间作为可操作对象”，让定位、裁剪、密采样与再定位构成可循环的取证过程。

空间维度工具对应“在同一时间片段内改变空间可见性”，典型代表是局部裁剪/放大（spatial-zoom）以读取文字、辨别细节等 [5]。但在综述口径上，空间维度不应只等同于 zoom：更一般地，它包括任何能在保持时间上下文的同时改变空间分辨率、关注区域或可见证据范围的操作。例如 VideoTemp-o3 明确把 cropping 作为核心工具调用之一，并强调其与时间定位/多轮细化的配套关系：cropping 并非单次前处理，而是“按需裁剪 + 反复细化”闭环的一部分 [4]。因此在对比时，可将“空间工具”表述为：是否支持输出可执行的空间操作参数（如裁剪框/区域 id）、是否与时间定位耦合（先定位再裁剪还是先裁剪再定位）、以及是否能在多轮交互中不断缩小空间证据范围。

第二个维度是“证据获取工具 vs 证据核验工具”。证据获取（acquisition）关注从长视频中提出候选证据并将其转化为模型可消费的上下文，例如检索片段、裁剪片段、在片段内密采样等；证据核验（verification）则回答“取回来的是否真相关、是否足以支撑当前推理步骤”。VideoExplorer 在 temporal grounder 内部显式加入 verification：使用 VLM 作为 verifier 评估检索片段相关性，无关结果丢弃、相关片段返还，从而降低无关片段诱发的幻觉并让高层规划聚焦于任务拆解 [3]。VideoTemp-o3 的数据构建流程也把核验机制制度化：在生成候选区间并裁剪后进行闭环一致性验证（closed-loop consistency verification），仅保留最终答案与 ground-truth 一致的样本；对长视频（>3min）还可多一轮 refinement，通过“再定位—再验证”的方式形成 multi-tool-call 训练数据 [4]。当对比不同系统的工具箱时，若只统计“有哪些操作”，容易忽略“是否有核验闭环”这一决定可靠性的结构差异；因此建议把核验工具作为与获取工具并列的一等类工具，并记录其触发条件（每次检索后都验证还是只在不确定时验证）、核验模型/规则的独立性（是否与主推理模型解耦）以及核验失败后的回退策略（丢弃、重检索或扩大窗口）。

第三个维度是“离线索引型工具 vs 在线交互型工具”。离线索引型工具强调对视频进行预处理与结构化存储，使在线推理时可以低成本地访问候选证据；在线交互型工具则强调在推理过程中即时产生操作参数、即时执行并把结果回填给推理链。VideoExplorer 明确采用离线分段与多模态嵌入库存储：离线阶段将视频切为 clips 并存为多模态 embedding；在线阶段 grounding agent 以文本或多模态查询匹配候选片段，并将“construction/retrieval/verification/summarization”动作结果返回给 planner [3]。与此不同，Video-CoM 更接近在线交互式工作台：模型在每一步选择 find-segment/find-frame/spatial-zoom 等操作，直接从原视频中截取片段/帧或裁剪区域并继续推理 [5]。在检索侧，ModaRoute 提供了另一种“离线索引 + 在线路由”的对比样例：系统预先构建 ASR/OCR/视觉三类索引，而在线由 LLM 路由器分析查询意图后只选择部分模态索引进行检索，平均每次查询使用 1.78 个模态而非穷举 3.0 个模态，并报告约 41% 的计算开销降低，同时维持 Recall@5=60.9% [7]。这提示在视频推理工具谱系中，“索引是否离线、在线调用是否选择性”是效率与可扩展性的重要分野。

第四个维度是“单次调用 vs 多轮细化”，用于刻画工具是否支持渐进式收敛到证据。多轮细化并不只是“多调用几次”，而是要求系统状态可携带（上一轮的证据、置信度、失败原因）并能驱动下一轮缩小搜索空间或改变采样预算。VideoTemp-o3 将 multi-turn grounding refinement 作为显式能力，并在数据层区分 multi-turn single-tool-call 与 multi-turn multi-tool-call：先生成候选片段并裁剪，若一致性验证失败则允许额外 refinement；同时作者把该流程限制在长视频（>3min），强调多轮细化与长时证据稀疏性之间的对应关系 [4]。VideoExplorer 的迭代机制同样体现“提出子问题—定位片段—调整粒度—再提出子问题”的循环，并在 token 效率分析中强调其通过聚焦高相关片

段实现“更少视觉 token 更好性能”[3]。在比较时，可把“是否多轮”进一步细分为：是否支持（1）时间边界的收缩/扩张，（2）采样密度的升降，（3）核验失败后的策略性回退，以及（4）多轮轨迹是否被用于训练（例如只监督末端回合还是监督全过程）。

第五个维度是“硬工具（可执行操作）vs 软工具（路由/策略/提示）”。硬工具是直接改变可见输入的操作（裁剪、检索片段、冻结帧、空间 zoom 等），其输出通常是可执行参数（时间段、帧号、裁剪框）与新的视觉上下文；软工具则不直接改动视频，而是决定“何时用什么工具、用哪个索引、以何种粒度与预算去看”，常体现为路由器、规划器、格式约束或训练期奖励等。VideoExplorer 的 planner 就属于高层软工具：它不直接“切视频”，但通过分解任务、提出子问题并指定所需时间区间与粒度，扮演调度器/控制器角色 [3]。ModaRoute 的 LLM router 也是软工具：它根据查询语言结构与语义预测哪些模态最可能包含信息，并进行 selective querying；系统还把“模态选择 + 查询优化”合并在同一提示中，从而把检索调用策略工具化、程序化 [7]。在训练对齐层面，VITAL 通过强制 rollout 输出具备 `<tool call>{...}</tool call>` 的格式，并施加严格的 rule-based 格式奖励 $R_{format}(\tau)$，把“工具调用以结构化接口输出”本身作为一种稳定化机制 [2]；Video-CoM 则进一步用逐步推理奖励对每一次 manipulation 的正确性打分（$R_{reason} = (1/N)\sum_i C_i$），把“工具是否用对”从最终答案中解耦出来 [5]。Video-VER 走的是另一条“软工具”路线：它在训练期使用外部多模态大模型生成与问题相关的视觉证据，并用 Visual Evidence Reward 显式奖励“可验证地扎根于视觉证据”的推理轨迹；同时强调外部视觉语言模型仅用于训练数据与奖励构建，测试期由策略模型独立推理，从而在“离线教师—在线推理主体”之间划分角色 [10]。这些例子表明，软工具往往决定系统是否能在预算受限、证据稀疏与易幻觉的条件下稳定运作；因此在对比框架中应把软工具与硬工具并列记录，而不是把路由/规划/奖励当作“非工具的实现细节”。

将上述维度组合起来，可以形成较统一的对比口径：对任一 think-with-video 系统，先说明其工具箱覆盖的“时/空操作轴”，再说明其在“证据获取—证据核验”链路上分别有哪些组件、是否解耦；随后交代其依赖的离线索引/预处理与在线交互接口；最后用“多轮细化能力”与“硬/软工具分工”刻画其可扩展性与可靠性来源。按此口径，诸如“find-segment（重访时间片段）”“video clipping/cropping（裁剪生成可操作的证据上下文）”“dense sampling（按需提高采样密度）”“verifier（过滤无关片段）”“closed-loop consistency verification（闭环一致性核验）”“LLM routing（选择性检索哪些模态索引）”以及“格式奖励/逐步奖励/证据奖励（将工具正确性与证据对齐显式化）”等机制，会自然落入不同维度的对比坐标，而不再被简化为放大与拆帧的同义替换 [2, 3, 4, 5, 7, 10]。

6 工具类别一：时间维度的检索、定位与裁剪工具

在“think with video”范式中，围绕时间轴的工具之所以被频繁外部化（或被显式建模为可调用模块），根本原因在于长视频的核心瓶颈往往不是“是否看见某一帧”，而是“在何时、以何种粒度、以多大预算去看哪些时间片段”，以及“如何把时间段证据可靠地回传给推理链”。与“拆帧/抽帧”相比，时间维度工具把视频访问从一次性的静态采样，升级为可迭代的检索—裁剪—复核闭环：模型能够先在全局建立假设，再提出子问题并定位候选时间窗，随后对该窗进行密集观察或重新观看，必要时继续细化时间边界直至获得足够证据 [3, 4]。

时间区间定位（temporal grounding）的一个关键增量价值，是将“抽象的信息需求”转译为“可执行的时间窗动作”。VideoExplorer 将该过程形式化为以子问题驱动的迭代机制：给定问题 $\mathbf{q}$，规划器在第 t 轮产生子查询 $\mathbf{q}_t^{\text{sub}}$，时间定位器根据子查询输出时间跨度 $\tau_t = \Gamma_{\text{ground}}(\mathbf{q}_t^{\text{sub}})$，感知模块再对该时间跨度执行可伸缩的理解 $\mathcal{P}_t = \Phi_{\text{perc}}(\tau_t)$，最终得到答案 $\mathcal{Y} = \Theta(\mathbf{q} \mid \{\mathcal{P}_t\}_{t=1}^{T})$[3]。这种“先定位、后感知”的分工，使得时间定位不仅是检索返回一个片段，更是推理链中对证据边界与预算的显式控制点：当子问题需要细粒度动作/瞬时事件时，系统可以在定位到的窄时间窗内密集采样以

提升保真；当子任务是全局角色、主题等宏观问题时，则覆盖更宽区间并采取粗采样以提升可扩展性 [3]。

“片段检索/重访（rewatch/find-segment）”进一步把时间定位落到可复用的原子操作上。Video-CoM 明确将推理建模为多轮交互轨迹，并在每一步从三种原子操作中选择其一：`find-segment`、`find-frame` 与 `spatial-zoom`；其中 `find-segment` 的定义是从原视频按段索引检索短时间片段 $V_{i+1} = g_{\text{clip}}(V_0, s)$，用于回看快速动作或关键瞬间，`find-frame` 则按帧索引抽取单帧高分辨率画面以冻结证据 [5]。为降低时间定位的操作成本与歧义，Video-CoM 还把视频预先切分为等长区间，并将 segment/frame 索引直接叠加在画面上，让“定位到哪一段/哪一帧”成为可验证的离散决策 [5]。这一设计的意义在于：即便同样是“抽帧”，当抽帧被组织为“在时间轴上跳转并重看”的可追溯动作时，它对推理过程提供的是可回溯的证据链，而非一次性输入的一组静态帧。

视频裁剪/截取（video clipping/cropping）是时间工具中最接近“人类播放器操作”的一类：先圈定时间窗，再把该窗作为后续推理的唯一证据来源，以减少无关片段带来的幻觉与漂移。VideoTempo3 将 thinking-with-videos 直接刻画为“localize-crop-answer”过程，并强调系统支持按需裁剪（on-demand grounding and cropping）以及多轮定位细化：模型可以在获得初始候选时间段后裁剪该段并据此作答，若证据不足则再进行一轮（或多轮）重定位与再裁剪，迭代直至收集到足够可靠的证据 [4]。其数据构建流程也把裁剪当作强约束：首先由外部强模型预测候选时间段并裁剪，将裁剪片段与原问题输入模型，同时“显式约束模型只能基于该片段回答”；随后通过闭环一致性验证，仅保留答案与标注一致的样本，并在长视频（>3min）上进一步允许额外一轮 refinement，形成多工具调用的多轮训练数据 [4]。这种把“裁剪后作答”写入数据与训练约束的做法，使裁剪不再只是工程加速手段，而成为提高证据可追责性的推理协议。

在临床长视频等高风险场景，裁剪往往被组织成“粗到细（coarse-to-fine）”的层级检查工具链。MedScope 提出交错式视觉链式思维（VCoT），在文本假设与工具取证之间交替推进，并给出了两种原生工具来支持层级化时间检查：`crop_video` 接受时间窗并返回该窗内“片段级的密集采样帧序列（clip-level densely sampled frame sequence）”用于局部取证；`get_frame` 接受时间戳并返回最邻近的三帧用于精细核验 [6]。这类工具的增量价值在于把“先粗检再精查”的临床观看习惯制度化：模型可以先用较粗时间窗定位候选操作步骤或关键转折，再用时间戳邻域的少量帧验证细节，从而在长程序视频中实现可控的证据寻访与复核循环 [6]。

时间分段索引与多模态嵌入库，使“定位/检索”可以在离线预处理与在线推理之间重新分配成本。VideoExplorer 提出在离线阶段把视频分割为 clips 并存储多模态嵌入；在线阶段由时间定位代理对查询与候选片段进行匹配，并将检索动作从主推理链中解耦出来。该代理不仅执行检索，还会把子查询转化为构造、检索、验证、总结等具体动作，并将经验证的片段返回给规划器 [3]。关键点不在于“是否有一个向量库”，而在于把时间定位实现为可执行子系统：它可接受文本或多模态查询，借助验证器过滤无关片段，并以较低认知负担向主推理链提供“已定位且已校验”的时间证据，从而降低无关片段引发的幻觉风险 [3]。

粗到细的多轮定位细化（multi-turn refinement）通常与“证据是否充足”的自我评估绑定：先产出一个低成本的粗定位，再根据回答失败或证据不充分的信号触发进一步收缩时间边界。VideoTempo3 将这种细化机制明确为多轮 grounding refinement，并在数据侧区分单工具调用与多工具调用轨迹，以覆盖“第一次裁剪就足够”与“需要再次裁剪”两类行为分布 [4]。MedScope 则从工具层面给出层级化动作空间，并在强化学习奖励里把“最终一次工具调用的证据对齐”显式纳入优化目标：证据项根据 `crop_video` 的时间窗重叠（temporal overlap/IoU）与 `get_frame` 的时间戳对齐进行评估，并对 `crop_video` 额外采用 IoU 奖励日程（bonus schedule）以鼓励更精确的时间窗选择 [6]。这种把“时间对齐质量”写进奖励的做法，实质上把多轮细化从启发式策略提升为可学习的行为：模型不仅要答对，还要在时间轴上把证据找得对。

在时间维度工具链中，“视频裁剪”相对“拆帧”的另一个增量价值是对幻觉的经验性抑制：当模型被迫围绕一个明确时间窗重看/密集观察时，它更容易在局部证据上达成一致，而不是在全局稀疏帧中用语言先验填空。VITAL 在对不同视觉工具的消融中观察到，加入 clip caption 或 clip QA 工具不仅未提升 temporal grounding 的结果，甚至会导致 mIoU 显著下降；相反，video clipping 在经验上相较其他工具更能减少幻觉 [2]。这提示一个重要工程事实：时间工具的有效性不仅取决于“信息量”，还取决于工具输出是否会引入新的语义噪声（例如自动字幕/问答的偏差），以及工具是否能把证据边界收紧到足以支撑可验证判断的时间窗。

与“定位片段后再密采样”并行的一条路线，是先用“时刻/片段检索模型”指导采样，从而在不显式多轮交互的情况下提高时间证据命中率。Moment Sampling 工作提出利用通用文本到视频 moment retrieval 模型来引导长视频问答的帧选择：其核心是使用轻量 moment retrieval（采用在 QVHighlights 上训练的 QD-DETR）从“视频 + 问题”预测相关 moments，并将 moment 相关性转为帧级得分；由于 moments 边界较硬，作者对帧级相关性进行高斯平滑以获得时间连续性，并叠加质量分（以拉普拉斯方差检测运动模糊）、均匀性分（鼓励时间分散）与聚类抑冗余等项，最终用贪心策略选取帧集合 [13]。从工具视角看，这相当于把“时间定位”封装为一个可插拔的检索器，为下游 VideoLLM 提供 query-aware 的时间优先级信号，弥补均匀采样在长时程推理中容易遗漏关键帧的缺陷 [13]。

最后，“何时检索什么”的路由策略并不只发生在时间轴内部（选哪一段），也发生在跨索引/跨工具的选择层面（先走哪条证据通道、花多少成本）。ModaRoute 把这一问题明确为由 LLM 驱动的检索路由：系统用 GPT-4.1 分析自然语言查询的结构与语义，预测应检索 ASR、OCR 与视觉索引中的哪些模态，并只查询被选模态，随后并行检索并通过排序融合得到最终结果 [7]。在其实验中，路由策略将平均每次查询的模态数从穷举的 3.0 降到 1.78，在 Recall@5=60.9% 的同时实现约 41% 的计算开销降低 [7]。对 think-with-video 系统而言，这类“路由工具”提供了一种更上层的时间预算调度方式：当问题的关键信息更可能存在于语音/屏幕文本/纯视觉事件的某一通道时，先做模态选择可以显著减少无效检索，再把剩余预算投入到真正需要的时间窗裁剪与密集观察中。

综上，时间维度工具把视频推理从“对一堆帧做一次性理解”重构为“在时间轴上可操作的证据搜寻过程”：时间区间定位提供可执行的证据边界，`find-segment`/rewatch 将回看固化为原子动作，裁剪与密采样把证据收缩到可验证窗口，分段嵌入库与解耦的 grounder 把检索从推理链中外部化并可插入验证/摘要，多轮细化与奖励对齐把“找得更准”变成可学习目标，而路由策略则决定在资源受限时优先打开哪条检索通道 [2, 3, 4, 5, 6, 13, 7]。

7 工具类别二：证据核验、过滤与摘要（降低幻觉/漂移）

长视频推理的“工具化”趋势并不只体现在放大、拆帧等感知层操作上，更关键的一支演化是围绕可靠性而引入的证据核验、过滤与摘要机制：一方面，长视频往往需要先经由检索/时间定位把候选片段从海量时序上下文中“拉进窗口”，这一步天然带来误召回与噪声；另一方面，即便片段检索正确，模型在生成长链推理时也可能被语言先验牵引，产生与视觉事实不一致的“漂移式幻觉”。因此，许多 think-with-video 系统把“验证器（verifier）”“闭环一致性检查”“证据过滤与对齐”“片段级摘要”显式做成可调用工具或可分离执行器，以降低无关片段诱发的幻觉、抑制推理链漂移，并在一定程度上提升可解释性边界。

在 VideoExplorer 的框架化描述中，可靠性首先被嵌入到“推理链—检索链”解耦的系统结构里：作者提出的 temporal grounder 被设计为独立于主推理链的执行器，离线将视频切分为 clips 并存入多模态嵌入库，在线阶段再用文本或多模态查询去匹配候选片段；更重要的是，它把抽象的子问题查询转译为一组具体动作（construction、retrieval、verification、summarization），并将“经验证的片

段”返回给高层 planner，而不是让 planner 直接在大量候选片段上进行端到端自由生成式推理 [3]。这种解耦的价值在于把易错且成本高的证据定位过程收束为更可控的执行模块：当验证环节判定某段检索结果与当前子问题无关时，系统可以直接丢弃该片段，仅将通过验证的证据交给 planner，从而减少“把无关片段当成证据”所触发的幻觉与错误归因 [3]。需要强调的是，这里 verifier 的角色更接近“证据过滤器”而非“答案裁判”，它的边界在于只能就“相关/不相关”“是否满足子问题约束”做判别；如果 verifier 自身存在系统性误判，那么它同样可能带来两类相反风险：误保留噪声片段导致幻觉污染，或误过滤关键证据导致后续推理在信息缺失下被迫依赖语言先验而猜测。

闭环一致性检查常被用来把“工具调用是否真的提升了答案可靠性”转化为可操作的筛选准则，尤其体现在多轮工具调用轨迹数据的构造阶段。VideoTemp-o3 将 thinking-with-videos 明确表述为“localize-crop-answer”的交互过程，并在其多轮、单工具调用数据生成流程中引入 closed-loop consistency verification：在用外部强模型提出候选时间段并裁剪后，训练样本只有在“最终答案与 ground-truth 保持一致”时才被保留，从而形成多轮对话但单次工具调用的训练数据 [4]。对于长视频（文中明确阈值为 $> 3\,\text{min}$），该流程允许再进行一轮 refinement；若在额外一轮细化后通过一致性检查，则保留为 multi-turn、multi-tool-call 训练数据 [4]。这种“以闭环一致性为门槛”的工具，其作用边界同样清晰：它能有效剔除由错误裁剪、错误定位或工具调用失败引入的噪声轨迹，提升训练数据的“工具调用—答案正确”同向性；但由于一致性判据通常依赖既有标注或标准答案，它对开放式问题（无唯一答案、或答案可被多种证据支持）以及对证据解释多样性的覆盖会更弱，也可能引入选择偏差，使保留下来的轨迹更偏向“易于通过一致性验证”的样本分布。

证据过滤不仅发生在训练数据层，也直接影响推理期的工具选型与证据形态。VITAL 的工具消融结果显示，并非所有看似“补充信息”的视觉工具都会提升时序定位或减少幻觉：作者观察到在 temporal grounding 任务上加入 clip caption 或 clip QA 工具不仅没有带来改进，反而会导致 mIoU 显著下降；相较之下，video clipping 在经验上比其他工具更能减少 hallucination[2]。该对比提示两点：其一，“更多中间描述”并不必然等价于“更可靠的证据”，当 caption/QA 本身携带生成噪声或把注意力从关键视觉细节转移到语言化概括时，反而可能放大漂移；其二，过滤与裁剪类工具（把证据边界收窄到更高置信的时空区域）往往更像“降噪操作”，其增益来自减少模型在无关上下文中自由联想的机会。与此相呼应的是，VideoExplorer 的 verifier 过滤、VideoTemp-o3 的一致性筛选，都在不同阶段把“证据边界”收敛为更少、更相关的片段，实质上是在用工具把推理的自由度约束在较小的、可解释的证据集合上。

为了直接对抗推理链的“视觉思维漂移（visual thinking drift）”，也有工作把“证据对齐”提升为可学习的训练目标，而非仅作为工程规则。When Thinking Drifts 指出 CoT 在视频推理中可能产生“冗长但误导性的内心独白”，导致幻觉的视觉细节甚至覆盖原本正确的直觉，并将其概括为 visual thinking drift[10]。该文提出 Visual Evidence Reward（VER），核心是奖励那些“可被视觉证据验证的推理轨迹”，并将 visual evidence 定义为与问题相关、回答所必需的视觉细节（question-dependent）[10]。在证据生成上，作者使用外部强 MLLM（Qwen2.5-VL-72B）在给定视频与问题的条件下生成答案与支持该答案的视觉观察列表；但策略模型 Video-VER 在测试阶段不依赖外部证据生成器独立推理 [10]。这种“训练期工具（teacher）/推理期去工具”的设计边界较为明确：它把证据抽取能力外包给强模型以获得监督信号，同时避免推理期把外部生成器引入为新的不确定性来源；但其有效性仍受制于证据生成质量与“可验证性”定义是否覆盖任务所需的全部关键细节，一旦证据列表遗漏或表述含混，奖励信号可能会把模型引向过度简化的证据模板。

摘要（summarization）在 think-with-video 体系中常作为“证据压缩”工具出现，其目标不是生成最终答案，而是把通过检索/验证的片段转写为更短、更易于多轮累积的中间表示，从而在窗口长度受限时维持跨回合的证据可用性。VideoExplorer 明确把 summarization 作为 temporal grounder 可执行的动作之一，并强调其返回的是“validated segments”供 planner 使用 [3]。从可靠性角度看，

片段级摘要的收益来自两方面：一是将模型的关注点从未过滤的原始帧序列转移到“已通过验证的片段内容”，降低无关细节干扰；二是在多步推理中提供可追溯的证据条目，使后续步骤更容易围绕同一组证据保持一致。然而摘要也存在典型边界：摘要是对原证据的二次生成，可能引入再一次的信息损失与措辞偏置；因此，在强调可解释性的系统里，摘要更适合被视为“缓存与路由用的压缩表征”，而不是替代原始证据的最终依据。

最后，证据核验与对齐并不只依赖视频领域专用模块，一些通用的“生成—验证—过滤”工具链也可迁移到视频推理的文本输出层。THaMES 在面向幻觉缓解与评测的端到端工具链中，展示了多种可工具化的质量控制手段：例如通过 RegEx 过滤掉包含歧义关键词、难以自包含的问题以降低评测集噪声，并引入 chain-of-verification prompting 来构造聚焦 ANSWER_ENTITY 与 QUESTION_ENTITY 的核验问题 [18]；其评测指标还给出了基于“支持性陈述占比”的忠实度定义，如 Answer Faithfulness $A_F = |V|/|S|$（$|V|$ 为被支持的陈述数，$|S|$ 为总陈述数）[18]。对于 think-with-video 系统而言，这类机制可以被视为“输出侧证据对齐器”：当模型完成片段检索、裁剪、摘要后，仍需在最终文本中把主张与证据陈述对齐，并通过核验式提问或陈述级评分来检测是否出现了超出证据的扩展。与数据/评测层的可靠性设计相配合，GLIMPSE 也通过双向问题对（bidirectional pairs）来检验一致性，只有两问均答对才计为正确；在该设置下，作者报告 GPT-4o 若只看正向问题准确率为 52.30%，但按问题对计分仅 28.80%，揭示了单向评测可能高估模型稳定性的问题 [12]。这类一致性评测工具并不直接减少幻觉，但它为“是否需要引入 verifier、过滤器、摘要器”等工具提供了更苛刻、更能暴露漂移的诊断信号，从而反向驱动工具链的设计与取舍。

8 工具类别三：跨模态辅助工具（文本/语音/屏幕信息抽取与对齐）

在“think with video”的工具使用语境里，跨模态辅助工具的共同目标并不是替代视觉证据，而是把视频中难以被单次视觉编码稳定捕获、却对推理至关重要的信息（语音内容、屏幕文字、字幕、幻灯片/文档结构、以及对事件的可读描述）外部化为可索引、可检索、可对齐、可核验的中间表示。与“zooming/拆帧”偏向低层像素可见性不同，ASR、OCR、captioning 与跨模态对齐工具更像是将视频转写为符号化证据的“感知翻译器”：它们把时间轴上的多源信号转换为可被 LLM/检索系统消费的文本或嵌入，并在需要时回溯到原视频片段以完成证据闭环。

语音侧的核心工具是自动语音识别（ASR）与转写对齐。其价值首先体现在“语义锚点”的生成：讲者在何时说了什么，常常直接决定问答、检索或定位的可行性。Video-TT 在对视频大模型鲁棒性的分析中指出，引入音频转写能显著提升鲁棒性表现，约有接近 15% 的相对增益，表明语音信息可作为补充证据帮助模型抵抗对抗式提问与语境扰动 [19]。在数据与系统实现层面，MaViLS（讲座视频—幻灯片对齐）明确把 ASR 作为对齐流水线的关键组件：作者使用 faster-whisper（约 1.55B 参数规模）对讲座音频生成转写，并将转写作为与幻灯片内容匹配的信号之一 [8]。这些实践暗示在长视频推理/检索任务中，ASR 不只是“额外输入模态”，更常被工程化为可调用工具——既可离线构建语音索引，也可在在线推理中按需补全证据。

与语音转写相对应，屏幕信息抽取侧的关键工具是 OCR 与“动态场景读屏”。其必要性来自视频中大量决策性信息以文字形态出现（字幕、UI 状态、路牌/标题卡、实验读数等），而这些信息往往既不等价于语音内容，也不一定能从粗粒度视觉描述中可靠恢复。ModaRoute 的动机陈述提供了一个量化例证：即便采用密集文本 caption 可以获得较高的检索召回（如 `Recall@5=75.9%`），其离线处理开销昂贵；同时，约 34% 的片段中存在“未被 ASR 捕获的场景文字”，提示仅靠语音通道会系统性漏掉屏幕文本证据 [7]。更进一步，VideoOCRBench 从基准评测角度刻画了视频 OCR 的难点：与静态图像 OCR 不同，视频 OCR 需要同时处理时间动态、帧选择与文字的时空定位；在小文本、移动文本与运动模糊条件下，多模态模型性能显著下降，并常出现字符幻觉或对短暂出现文本

的漏检，暴露出“读屏工具”自身也可能成为误差源 [9]。因此，在工具链设计上，OCR 往往需要与时间定位/帧选择、文本区域裁剪或跟踪等操作耦合，而不是把 OCR 视为对任意帧的单次静态读取。

在“把视频转写为可推理证据”的方向上，captioning（通用或问题相关的片段描述）与多源文本化管线常被当作跨模态辅助工具使用。Language as the Medium 的两阶段框架展示了典型做法：感知阶段分别用 BLIP-2 从抽样帧生成视觉 caption（每个视频仅处理 5 帧等距采样以保持多样性）、用 Whisper（Faster Whisper）生成转写、再用 ImageBind 生成音频标签；推理阶段让 LLM 只基于这些“文本代理线索”完成零样本动作分类，并通过结构化输出约束保证下游可解析 [20]。在“Thinking with Video”一类以视频生成为推理介质的工作中，跨模态辅助工具还被用于把生成视频转回可评测的答案：例如对生成视频进行音频抽取并用 whisper-1 转写、对末帧或跨帧抽样结果进行评估，以及采用多数投票聚合跨帧信息；同时使用 LLM-as-a-Judge（如 GPT-4o）对末帧图像或转写文本进行判题，从而把视频/音频证据折叠到可比较的评测接口 [1]。这些例子说明，caption/转写/评审并非仅是“预处理”，而是在推理闭环中充当读出器（reader）与裁判（judge）的工具角色，决定了系统如何把多模态证据转化为可验证结论。

跨模态辅助工具进一步发展到“视频—外部文档/结构”的对齐与导航时，其价值会从单点信息抽取升级为时间轴的结构化索引。MaViLS 将讲座视频与 PDF 幻灯片对齐：算法综合语音转写、OCR 文本与图像特征计算相似度，并在相似度矩阵上用动态规划寻找最优幻灯片序列；实验上，组合策略的平均准确率达到 0.82，相比 SIFT 基线 0.56 有显著提升，并在运行时上约快 11 倍（约 3.5–4.6 分钟对比 39.5 分钟）[8]。更关键的是，MaViLS 的标注把每句讲者语句映射到幻灯片并给出视频时间戳，且当无幻灯片或幻灯片不可唯一识别时用 -1 标注，这类“允许缺失/歧义”的标签设计恰好对应真实场景中对齐工具必须处理的开放世界噪声 [8]。在 tool-using 视角下，视频—幻灯片/文档对齐相当于给长视频提供“外部锚点”（slide id、页面结构、标题层级），使后续问答、检索、证据引用可以围绕文档结构而非纯时间戳组织。

当系统同时拥有 ASR、OCR 与视觉索引时，如何决定“何时用哪个工具”本身就会成为一类跨模态路由工具。ModaRoute 把多模态视频检索中的模态选择外显为 LLM 驱动的路由决策：系统用 GPT-4.1 分析自然语言查询并预测相关信息最可能出现于 ASR（spoken content）、OCR（on-screen text）或 VISUAL（purely visual scenes）索引中，只检索被选模态并进行基于排序的融合 [7]。在 1.8M clip 子集与 2,195 条查询的评测中，其平均每条查询检索模态数从穷举的 3.0 降至 1.78，在 `Recall@5=60.9%` 的同时实现约 41% 的计算开销降低 [7]。但路由误差也揭示了跨模态工具链的典型失败模式：单模态路由准确率分解中，视觉查询识别可达 99.4%，ASR 为 71.7%，而 OCR 仅 42.9%，且常因字幕导致 ASR/OCR 混淆、以及视觉描述中包含文本线索造成 OCR 与视觉重叠；多数失败表现为“需要 OCR 时未选择 OCR”的保守偏置 [7]。这意味着跨模态辅助工具在提升覆盖面的同时，也引入了新的不确定性来源：工具输出噪声、路由器对信息载体的误判，以及不同模态间语义重叠导致的证据归因歧义。

综上，ASR、OCR、captioning 与跨模态对齐/路由工具把“视频中信息的载体差异”转化为可操作的工具接口，使系统能用文本化证据补齐视觉证据的盲区，并在长视频场景中形成更可检索、可追溯的证据结构。然而，这类工具并不天然可靠：ASR 会遗漏场景文字，OCR 在运动模糊与短暂文本上易失败并产生字符幻觉，captioning 可能把语言先验注入证据而导致“看似合理但不可核验”的描述；而模态路由又会因字幕混淆与跨模态重叠造成工具调用的系统性偏差 [7, 9]。因此，在 think-with-video 的工具谱系里，跨模态辅助工具更适合被理解为“证据生产与索引工具”，其输出需要与原始视觉片段保持可回溯连接，并与后续的证据核验/验证机制协同，才能在提升信息覆盖的同时避免把噪声证据放大为推理漂移。

9 工具类别四：对象级与运动证据工具（跟踪、分割与运动表征）

在 *think-with-video* 的工具谱系中，对象级与运动证据工具的增量价值不在于“看得更清楚”（如放大）或“看更多帧”（如拆帧），而在于把跨时间的连续性与可指代实体显式结构化：将“这个人/这个杯子/这把器械”在每一帧的位置、形状及其随时间发生的位移、遮挡与再出现，转化为可检索、可核验、可复用的中间证据。以 Video-CoM 为代表的交互式范式强调人类会通过 pause/rewatch/focus 形成主动感知回路，并将推理组织为一系列可解释的视觉操作；其原子操作除了局部放大与关键帧定位外，还包含按时间段回看（find-segment）以复核快速动作或关键瞬间，从而在推理过程中持续刷新证据 [5]。但当任务需要“持续指代”（长期跟踪同一实体）、需要明确“动作边界”（动作何时开始/结束），或需要把多个事件以“因果链”串联起来时，仅靠片段回看与关键帧抽取往往不足；此时，目标跟踪、视频分割与掩膜传播、跨镜头重识别（re-ID），以及光流/相位等运动表征，可作为更底层、更通用的工具组件，为高层规划与问答提供可计算的对象—运动证据。值得注意的是，在腹腔镜/手术视频等高风险长视频场景，“器械（tool）跟踪”本身也构成对象级证据工具的一类代表：弱监督的卷积 LSTM 工具跟踪方法强调在有限标注下对手术器械轨迹进行时序建模 [27]，而面向多类别、多器械的细粒度跟踪系统（如 SurgiTrack）则进一步把“多工具同时在场、遮挡频繁、外观相似”的复杂性作为核心挑战来处理 [28]。

对象级工具的核心原语之一，是“在每帧产出掩膜并维持身份一致性”。Tracking Anything with Decoupled Video Segmentation（TAD）将“在视频里跟踪任意目标”的问题显式解耦为两步：逐帧分割与跨时间的身份传播。该方法是类无关（class-agnostic）的：给定首帧对目标的指定（掩膜或边界框），在后续每一帧预测该目标的分割掩膜。实现上，逐帧分割部分建立在强图像分割基础模型之上，并通过从上一帧预测派生的提示（prompt）将图像分割适配到视频序列；身份维持则通过目标关联机制，将当前帧掩膜与既有轨迹匹配，匹配特征包含掩膜 IoU 与外观嵌入（appearance embeddings），从而把“掩膜”升级为“带身份的掩膜序列”[21]。这种解耦后的工具形态对 *think-with-video* 很关键：逐帧分割器可以“可插拔”升级，而身份传播模块相对轻量，使系统在需要时能够调用“追踪工具”来回答长时连续性的子问题，而不必对整段视频端到端重新编码 [21]。同时，TAD 也揭示了对象级证据工具的脆弱环节：快速运动、严重遮挡与显著外观变化会导致逐帧分割漂移、身份关联歧义增大，从而破坏“持续指代”的证据基础 [21]。

围绕“掩膜传播”这一经典视频分割工具，VS-ReID 给出了一种面向长期稳定性的模块化组合：其指出仅依赖时间连续性的掩膜传播在动态场景中容易漂移（drifting）并难以处理大位移，因此在传播链路中引入自适应对象再识别（re-identification）以避免目标被“跟丢”[26]。其结构由掩膜传播模块与 ReID 模块组成：前者通过光流引导的 warping 传播概率图，具体做法是使用 FlowNet2.0 提取帧间光流 $f_{i\to j}$，并用双线性 warping 函数 W 将概率图 $P_{i,k}$ 变换为 $P_{i\to j,k}$，以得到相邻帧的粗估计；后者在传播过程中检索缺失实例，若以高置信度再识别到丢失目标，则赋予更高优先级以在后续传播中恢复掩膜 [26]。由于“多轮迭代传播 + 再识别找回”可能引入新的覆盖错误，VS-ReID 还设计了 checkpointing 机制：用变量 $c_{i,k}$ 记录概率图的更新起点，使概率图更倾向于被较近起点更新，降低迭代中可靠结果被不良覆盖的风险 [26]。在结果层面，作者报告该两模块迭代机制在 2017 DAVIS Challenge 上取得 global mean 0.699（Region Jaccard 与 Boundary F 的综合）；并在消融中观察到把输入从全图改为边界框 patch 能将 global mean 提升 3.8%、边界 F 指标提升 5.1%，提示“局部化的对象证据”与“边界质量”对长期分割/跟踪链路同样关键 [26]。从工具调用视角看，VS-ReID 的启示是：即便高层代理已经用时间定位工具找到相关片段，仍可能需要一个“对象级检索/找回工具”（re-ID）来处理遮挡、离画、姿态变化等导致的身份断裂，否则因果链中的关键实体会在证据层面丢失，进而带来后续推理漂移。

除了通过更强的“再识别找回”稳住身份，另一类同样具有工具化潜力的思路是引入“端点约

束”与“双向传播”，将时间轴两端的可靠证据作为中间帧推断的锚点。Two-shot Video Object Segmentation 研究了一种新的 VOS 设定：只提供首帧与末帧的目标标注（two-shot VOS），比传统只标注首帧的 semi-supervised VOS 更具挑战，因为目标可能发生巨大外观变化，甚至消失后再出现 [25]。其基线策略较为直接：从首帧向前传播掩膜、从末帧向后传播掩膜，然后对每个中间帧融合两路预测；评测协议在 DAVIS 与 YouTube-VOS 等数据上用首末帧真值掩膜构造 two-shot 基准，并报告双端标注相较仅用首帧带来性能提升 [25]。对 *think-with-video* 系统而言，这类“双向传播 + 端点融合”可封装为可复用组件：当问题要求回溯某个对象“最终去了哪里”，或需要验证“某物是否在结尾再次出现”时，系统可以先在尾端获得高置信锚点，再通过后向传播把证据送回到早期时刻，从而降低仅靠前向跟踪造成的累计漂移；其失败模式（目标长时间完全遮挡，或前后向传播都不可靠）也提示了工具切换条件——遮挡跨度过长时，往往需要引入 re-ID 或检索式重定位，而不只是继续传播 [25]。

运动证据工具为“动作边界”和“因果链”提供了另一条证据通路：通过显式或隐式地估计跨帧对应与运动变化，把“发生了什么动作、何时发生、由谁引起”从纯文本推断转为可计算的运动线索。SegFlow 提出端到端可训练网络，用于联合优化视频目标分割与光流估计，并通过双向特征传播（bi-directional feature propagations）使分割与光流互相促进；为缓解需要同时具备分割与光流真值的大规模数据约束，还提出迭代训练策略 [23]。在 DAVIS 上，作者的消融表明离线训练对分割结果影响显著，可将 J_{mean} 提升 21%；进一步结合在线与迭代策略还能再提升 7.9%；运行效率方面，离线模型在 Titan X（12GB）上可同时输出分割与光流，约 0.3s/帧 [23]。这类联合学习的意义在于将“对象边界”（来自分割）与“像素对应/位移”（来自光流）耦合：当系统需要判断“对象何时开始移动”“是否发生接触/碰撞导致方向改变”时，光流的端点误差或方向突变可为动作边界提供客观信号，而分割则给出运动主体的空间支持集，从而减少背景运动干扰。

Every Frame Counts（EFC）进一步将“光流—分割”的互补关系工具化为可利用未标注视频帧的时序一致性约束：其动机之一是避免在推理前预计算光流，并充分利用未标注的视频数据；作者指出语义分割可提供语义信息以帮助识别遮挡，从而使光流更鲁棒，而非遮挡区域的光流又能提供准确像素级对应以保证分割的时序一致性 [24]。在训练组织上，EFC 以相邻帧对作为输入，随机选择近邻帧间隔 $t \in [1, 5]$；如果帧对中任一帧具备语义标签，则同时使用监督约束与基于近邻对应的无监督约束更新网络 [24]。它将光度一致性从像素域推广到特征域：对帧 I_i 和 I_{i+t} 提取特征 S_i 与 S_{i+t}，并学习正向与反向光流 $F_{i\to i+t}$、$F_{i+t\to i}$；用光流将 S_{i+t} warp 得到 S'_{i+t}，期望其与 S_i 一致。同时通过遮挡图（occlusion map）避免对遮挡区域施加一致性惩罚，一致性损失写作

$$L_{\text{cons}} = \sum_{x,y} (1 - O_{\text{est}}^{xy}) \, \|S_{i+t}'^{\,xy} - S_i^{xy}\|^2 \tag{1}$$

并将“遮挡”定义为两帧间缺失/不一致像素（可由真实遮挡、出入画、视角变化等造成）[24]。数据层面，EFC 的设定贴近“稀疏标注”视频：例如 Cityscapes 包含 5,000 个片段，每段 30 帧，但只有第 20 帧有精细像素级标注，同时还有 20,000 张粗标图像；评测使用分割 mIoU 与光流平均端点误差（EPE）[24]。对 *think-with-video* 而言，EFC 的思想不一定要以端到端训练形态出现，更可被抽象为“运动对齐/一致性检查器”：当推理需要核验“同一对象在两时刻是否仍为同一实体”、或区分“属性变化是否由遮挡/视角切换造成”时，基于光流 warp 的特征一致性与遮挡掩膜可作为证据核验工具，帮助将“不可见导致的不确定性”与“真实状态改变”区分开来，避免把遮挡误判为因果事件。

除光流外，运动表征还存在更轻量或更稳健的替代算子。Using phase instead of optical flow for action recognition 提出用欧拉式（Eulerian）的相位运动表征服务动作识别：其理论依据来自傅里叶位移定理（shift theorem），即时间域位移对应频域相关的线性相位变化，因此相位变化可作为运动表示；方法用复数域卷积层学习一组复数 Gabor 滤波器并从响应计算相位，随后利用相位的时间梯

度编码运动，并将其送入后续网络层 [22]。为适配“描述运动而非精确估计速度”的需求，作者从需要精确相位等值线的 quadrature filters 放宽到更简单的 perpendicular complex filters，并通过固定实部滤波器不参与梯度、仅更新虚部滤波器并周期性把实部重置为虚部旋转 $\pi/2$ 的版本来维持正交性 [22]。实验在 UCF101（101 类动作、平均约 180 帧/视频、标准划分）上进行；对比 Two-Stream、TSN、Motion Vectors、ActionFlow 等方法时，作者报告 PhaseStream 的 temporal stream 优于 ActionFlow，但略低于 Motion Vectors 与 Two-Stream ResNets；其训练输入之一是 5 张灰度帧时间导数堆叠（5×dGray）[22]。该工作也指出相位表征在噪声输入与高速动作场景下存在困难 [22]。从工具视角看，相位/时间导数提供了一种“以更低成本捕捉变化”的运动线索：在长视频推理预算受限时，系统可先用相位或帧差等廉价算子筛查高动态片段或动作边界候选，再触发更昂贵的光流或对象分割跟踪，形成粗到细的运动证据调度。

将这些对象级与运动工具接入 *think-with-video* 推理链时，通常可直接对应三类推理需求：

1. 持续指代：多步语言推理会反复提及同一实体（“她”“那把剪刀”“刚才掉下去的杯子”），而片段级摘要容易在遮挡或镜头切换处断裂；此时，TAD 的身份传播（掩膜 IoU + 外观嵌入匹配）或 VS-ReID 的“传播 + re-ID 找回”，能够显式提供实体轨迹，并在身份不确定时暴露失败条件（快速运动/遮挡/外观变化）以触发补救调用 [21, 26]。

2. 动作边界：从静止到运动、从接触到分离、从遮挡到再出现等边界，往往在帧级语义上不明显，却会在运动一致性破坏、光流场突变、或对象掩膜拓扑变化上出现信号；SegFlow、EFC 这类耦合光流与分割的工具链提供了用 warp、一致性与遮挡掩膜界定“可对齐的连续区间”与“不可对齐的变化点”的手段，使边界判断更接近可计算证据而非启发式猜测 [23, 24]。

3. 因果链：当任务要求解释“为什么发生了某事”或“哪个动作导致哪个结果”时，系统需要把多个对象的交互（接触、碰撞、遮挡、交换位置）按时间串联；对象掩膜序列提供“谁在何处”的状态变量，光流/相位等运动表征提供“如何变化”的动态变量，而 re-ID 与端点约束（two-shot 的首末帧锚点）则在长期跨度上提供“同一实体”的跨时链接，从而更容易形成可核验的因果链条，而不是仅在文本空间中补全 [25, 26, 22]。

总体而言，对象级与运动证据工具更像可被规划器按需调度的“证据生产器/核验器”：当推理需要确认“同一对象是否在遮挡后再次出现”时，调用 re-ID 或双向传播；当需要找到“动作开始的确切时刻”时，先用廉价运动算子提出候选，再用光流—分割一致性或掩膜拓扑变化精定位。工具使用由此从“看更多/看更大”转向“以对象与运动的结构化证据支撑长期、可指代、可验证的推理”。

10 工具调用策略与训练对齐：从格式约束到轨迹级优化

在 think-with-video 框架中，工具调用并不是“把更多视觉算子挂到模型外面”就自然稳定发生的能力，而是一个需要被显式学习、被约束输出接口、并在多轮交互轨迹上被对齐的决策过程。许多工作把“推理（thought）—工具动作（tool call）—环境观测（tool response）—再推理”的循环视为一个序列决策问题：智能体在生成中间思考的同时，必须决定何时去视频环境中寻找新证据、调用哪一个工具、以及是否已经获得足够证据可以结束交互并给出最终答案 [11, 3]。该类过程一旦进入强化学习或偏好优化阶段，训练信号会同时作用于语言生成质量、证据获取质量与工具调用成本，若不设计额外约束，容易出现“工具乱用、过度调用、或用不相关证据拼出看似合理答案”的不稳定行为 [11, 4]。

首先，输出格式约束往往是工具调用得以规模化训练的前置条件，因为工具调用必须落到一个可解析、可校验的动作接口上，否则训练阶段难以为“动作是否正确执行、轨迹是否可复现”提供明确监督。VITAL 为了“稳定思考与工具调用”，明确要求采样轨迹以 `<think>...</think><tool_call>{"name": "…", "arguments": {…}}</tool_call>...<answer>...</answer>` 的结构化形式输出，并配合严格的基于规则的格式奖励 $R_{\text{format}}(\tau)$ 进行约束；该做法将工具调用从自然语言中剥离成可执行的 JSON 参数，使得后续的奖励计算与轨迹过滤可以以确定性方式进行 [2]。在临床长视频的 MedScope 中，结构化接口被进一步扩展为在每轮轨迹中显式区分 `<think>`（文本理据）、`<tool_call>`（视觉理据/动作）、`<tool_response>`（环境观测）与 `<answer>`（终止预测），并把“是否遵守接口”直接作为复合奖励的一部分，用于把工具调用行为纳入与正确性同等地位的优化目标 [6]。这类“接口—解析—奖励”闭环也能反向影响数据生产：当数据合成和训练都以结构化格式为中心时，轨迹级过滤、纠错与再标注将显著更容易自动化 [6, 4]。

仅靠格式约束仍不足以让模型学会“每一步该不该调用工具、调用后是否真的拿到了证据”。因此，逐步操作正确性奖励成为许多 think-with-video 强化学习算法的核心：它把轨迹中的工具动作当作可评估的中间目标，而不是只看最终答案对错。Video-CoM 把交互式视频推理建模为“Chain of Manipulations”，每步从三种原子操作中选择其一：按段重访的 `find-segment`、冻结关键帧的 `find-frame`、以及对局部区域裁剪放大的 `spatial-zoom`[5]。为了避免“只要最终答对就不区分中间步骤好坏”的信号稀疏问题，Video-CoM 在 GRPO 基础上提出 RA-GRPO，通过逐步推理奖励 R_{reason} 显式评估每个 manipulation 的正确性，并以 $R_{\text{reason}} = \frac{1}{N}\sum_i C_i$ 的形式将所有步骤的正确性平均汇总，使策略梯度能直接朝“操作序列更对齐证据”的方向更新 [5]。MedScope 的复合奖励也在同一思想下引入证据项 R_{evidence}：它不只问“答案是否正确”，而是根据最后一次工具调用是否与标注证据时间对齐来计分；对 `crop_video` 用时间重叠/IoU 评估，对 `get_frame` 用时间戳对齐评估，并对裁剪类工具加入 IoU 递进式 bonus schedule，从而把“粗到细定位—取证—核验”的行为链条转化为可学习的强化学习信号 [6]。

当奖励开始直接绑定 temporal IoU、时间戳对齐等指标时，另一个问题随之出现：模型可能通过“投机性定位”在指标上获得高分，而并未真正形成可解释、可复用的证据定位策略，即强化学习中的 reward hacking。VideoTemp-o3 明确指出“仅用 IoU 作为奖励”会导致模型“任意定位来 hack reward”，因此提出 penalty-aware IoU reward：在 IoU 奖励之外对低质量的定位行为施加显式惩罚，以抑制胡乱猜测式的定位并鼓励更可靠的多轮细化 [4]。这一点提示：工具学习中的奖励设计往往需要同时包含“对齐奖励”与“行为约束项”，前者推动模型接近目标，后者避免模型在指标空间钻漏洞。类似的“成本/惩罚”也体现在推理效率维度：Video-Thinker 的 RL 训练除了答案正确性外，还会对过度工具调用施加惩罚以平衡性能与效率，避免智能体在简单问题上“工具过调用”造成不必要开销 [11]。

多工具、多任务的 think-with-video 训练还面临一个更宏观的优化难题：不同任务和不同样本的学习难度差异会在多任务强化学习中放大，导致训练过程被“容易提升的子任务”主导，从而让工具策略在真正困难的长视频定位任务上学不到关键能力。VITAL 在多任务 RL 中观察到 task-wise 难度不均衡：短视频或简单任务（例如多选题）奖励上升很快，但长视频 temporal grounding 的 IoU 奖励增长更慢；同时还存在 sample-wise 不均衡，即随着 RL 训练推进，易样本比例升高而难样本比例下降 [2]。为此其提出 Difficulty-aware GRPO（DGRPO）来处理难度不均衡，并在 GRPO 目标中保留与参考策略的 KL 约束项，以稳定策略更新。其优化目标写为

$$J_{\text{GRPO}}(\theta) = \mathbb{E}_{q\sim p(Q),\,\tau_k\sim\pi_\theta(\cdot|q)}\Big[\frac{1}{G}\sum_{k=1}^{G}\frac{\pi_\theta(\tau_k \mid q)}{\pi_{\theta_{\text{ref}}}(\tau_k \mid q)}A_k - \beta D_{\text{KL}}(\pi_\theta\|\pi_{\theta_{\text{ref}}})\Big], \tag{2}$$

并通过难度感知的奖励平衡，使多任务训练不至于被“容易的奖励通道”吞噬，从而在需要工具定位

与证据裁剪的任务上保持学习压力 [2]。从可复现的训练细节看，VITAL 在 SFT 与 RL 阶段采用不同学习率（SFT 为 1×10^{-5}，RL 为 1×10^{-6}）、不同 batch size（SFT 256，RL 64），并在 DGRPO 中使用 8 个 rollouts；这些工程化设置反映出工具学习通常对训练稳定性更敏感，需要在采样数与 KL 正则之间做更谨慎的折中 [2]。

除强化学习外，结构化模仿学习与轨迹级偏好优化正在成为“把工具使用变成稳定技能”的另一条主线，因为工具调用本质上是多轮轨迹的结构问题：一条轨迹是否好，不仅取决于答案是否正确，也取决于子问题分解、证据检索、验证与结束时机是否合理。VideoExplorer 在训练上首先进行结构化模仿的 SFT，强调学习复现“专家推理痕迹（reasoning traces）”而非仅拟合最终答案；随后引入 trajectory-based direct preference optimization（TDPO），把 DPO 从单轮输出扩展到多轮、多步视频推理场景，对“整条推理轨迹”进行偏好学习，使训练目标能够同时覆盖中间步骤质量与最终结果 [3]。与之相呼应，VideoTemp-o3 在多轮对话式工具调用数据上采用统一 masking：只对最后两轮输出施加损失，前序回合与输入不参与梯度，从而降低早期回合定位噪声对学习的干扰；这可以理解为在监督信号有限时，对轨迹中“决定性步骤”进行加权的对齐策略 [4]。

上述对齐方法的效果高度依赖“单工具调用/多工具调用”训练数据如何构建，以及质量控制是否能覆盖工具动作层面的正确性。VideoTemp-o3 的数据流水线体现了这种数据—对齐共设计：其多轮工具调用样本由强模型先预测候选时间片段并裁剪，再强制模型“仅基于该片段作答”；随后进行闭环一致性验证（closed-loop consistency verification），只有当最终答案与真值一致时才保留样本，形成 multi-turn、single-tool-call 数据；对长视频（>3min）再允许额外一轮 refinement，通过“再定位—再裁剪”保留通过样本为 multi-tool-call 数据 [4]。Video-CoM 的数据构建同样强调端到端的轨迹可控性：每个视频预先等长分段，并把 segment 与 frame index 直接叠加到帧上，使 `find-segment`、`find-frame` 等动作具有可标注、可比对的离散目标；其 Video-CoM-Instruct-18K 从约 9K 视频出发，用 Gemini-2.5-Pro 为每个视频生成 3–5 个 QA（总计 25K），经验证后保留约 75% 得到 18K 高质量样本，并明确划分 15K 用于 SFT、3K 用于 GRPO/RA-GRPO[5]。VideoExplorer 的数据更强调覆盖复杂推理：通过 difficulty-adaptive sampling 先均匀采样任务、生成轨迹，再根据首轮准确率对困难样例重采样，并“仅保留正确答案轨迹”以确保有效性；其最终整理出 11.1k planner trajectories 与 10.8k grounding trajectories，为分模块训练（规划器与时间定位器）提供了可分离的监督材料 [3]。

质量控制除了“答案一致性/正确性过滤”，在工具学习里还必须防止模型利用数据捷径学会绕开工具或伪造证据。MedScope 的 ClinVideoSuite 合成流程中，先构造带时间戳的密集字幕作为局部证据并用低采样摘要保留全局上下文，再通过跨模型投票的级联过滤去除知识驱动问题、摘要模型捷径与内部不一致样本，最后进行多模态确认：直接从视频片段 $\mathrm{Clip}(V, w)$ 回答问题，以消除字幕幻觉并保证问题确实依赖视频证据；在此基础上再通过真实环境交互合成 visual-CoT 轨迹，得到既包含 tool-augmented 也包含 tool-free 的轨迹分布，用于训练“何时需要工具”的决策边界 [6]。这类数据验证思路与 VideoExplorer 的“检索—验证—总结”执行链相呼应：其时间定位代理在推理时会用 VLM 作为 verifier 丢弃无关片段，把通过验证的片段回传给规划器，从系统层面把“错误证据”阻断在进入主推理链之前 [3]。

工具调用策略的学习还可以被理解为一种“路由/预算分配”问题：不是所有查询都应调用所有工具，也不是每次调用都需要最昂贵的模态或最高密度的观测。ModaRoute 将这一点在检索任务中做了量化：它用 LLM 路由器根据查询意图在 ASR、OCR 与视觉索引之间做选择性检索，平均每次查询只用 1.78 个模态（而穷举是 3.0），在保持 Recall@5=60.9% 的同时把计算成本降低约 41%，并指出路由失败主要集中在 OCR 需求识别（单模态路由中视觉 99.4% 准确、ASR 71.7%、OCR 42.9%）以及字幕导致的 ASR/OCR 混淆 [7]。这类结果对视频智能体同样具有启示：工具调用对齐不仅是“动作能否对上 GT 区间”，也包含“是否能识别信息源在哪、是否值得花成本去查”的策略

学习，且误差常来自模态间语义重叠与保守偏置 [7]。

最后，许多工作开始把“证据对齐”从系统工程上升为训练目标，以缓解多轮推理中常见的幻觉与推理漂移问题。When Thinking Drifts 的分析指出，视频推理中的 CoT 往往因为缺乏对 CoT token 的显式监督而偏离视觉证据，生成冗长但误导性的内心独白并覆盖原本正确的直觉；其提出 Visual Evidence Reward（VER），用强化学习显式奖励“可验证地 grounded 在视觉证据上”的推理轨迹，并用强外部 MLLM（Qwen2.5-VL-72B）离线生成问题相关视觉证据作为训练依据，而测试时策略模型独立推理不依赖外部证据生成器，从而把“工具/教师模型”限定在训练期以降低推理期依赖 [10]。从更广义的工具观出发，Video Language Planning 甚至把视频（尤其是想象 rollout）作为语言计划与低层动作之间的中间表征，指出这种视频化表征天然支持放大、抽帧、按时间查询场景属性等视觉工具操作，并可将这些操作应用到“想象视频”上做可行性审查；这为 think-with-video 的训练对齐提供了另一条路径：工具不仅用于回答问题，也可用于规划阶段的自我检查与反事实比较，但其有效性同样受限于生成/预测视频在长时域上的误差累积 [29]。

综上，think-with-video 中工具调用的可学习性与稳定性，依赖一套从“接口格式 → 奖励分解 → 反作弊惩罚 → 难度平衡 → 轨迹级对齐 → 数据构建与质量控制”的系统性设计。格式奖励把动作空间变成可解析对象并为自动化验证铺路 [2, 6]；逐步奖励与证据奖励让工具动作本身获得密集、可比较的训练信号 [5, 6]；惩罚项与成本项分别应对 reward hacking 与过度调用等典型失效模式 [4, 11]；难度感知的多任务 RL 试图把训练压力重新分配给真正困难的长视频定位/取证任务 [2]；而结构化模仿与轨迹级偏好优化则把“整条交互轨迹”作为对齐对象，使工具调用从局部动作正确扩展到全局策略合理 [3]。在这一框架下，“除 zooming、拆帧以外是否有更多工具”的问题最终会落到训练对齐：工具越多，越需要可扩展的轨迹标注、自动验证与可解释奖励，才能避免工具箱扩大反而带来不稳定与幻觉累积。

11 评测与分析：基准任务、消融设置与效率指标

围绕“think with video”的工具使用进行评测时，一个反复出现的困难是：同一套工具链往往同时改变了模型的“看什么”（检索/采样/裁剪带来的证据覆盖变化）与“怎么想”（多轮交互、验证、结构化轨迹与奖励机制），因此仅以最终问答准确率作单一判断，容易把证据获取不足、证据核验失败与语言推理偏差混在一起。更稳健的评测通常会把目标拆成三类可测对象：其一是任务层面的最终正确性（QA、分类、生成质量等）；其二是过程层面的证据定位/操作正确性（时间段、关键帧、空间区域、轨迹的一致性）；其三是系统层面的效率与稳定性（视觉 token、检索成本、路由误差、奖励黑客与幻觉风险）。在这一拆分下，基准任务的选择决定了“工具是否带来有效增益”能否被识别，而消融与效率指标则决定了不同方法之间能否形成可比结论。

长视频问答（long-form VideoQA）仍是工具增强范式最常见的落点之一，因为它天然要求模型在窗口受限的前提下进行证据选择与跨时段整合。在工具增强强化学习框架中，VITAL 选择了长视频问答基准 Video-MME、长视频推理基准 LongVideo-Reason (LVR)，以及长视频时间定位基准 VidChapters-7M 与 VUE-TR 作为评测集合，从而把“答对问题”与“找对片段”放在同一实验矩阵中对齐比较 [2]。与之互补的工作会直接把“按问题选择关键证据”设计成外部模块：例如 moment sampling 以文本-视频 moment retrieval 模型（QD-DETR）提供相关时间片段线索，再将其转化为帧级相关性分数以指导下游 VideoLLM 选帧，实验覆盖多个公开视频长视频问答数据集与不同 VideoLLM（含闭源 API 模型与开源模型）[13]。这类“检索/采样工具驱动”的评测更容易把工具效果归因到证据选择环节，但也要求在报告中明确：moment retrieval 的额外计算、离线索引成本、以及其跨域泛化对最终增益的影响边界。

若研究目标强调“工具调用应当可解释且能对齐人类顺序推理”，则需要更细粒度的时空推理

基准来拆解 when/where/what 等子能力。V-STaR 明确把视频推理分解为“what（对象/事实）—when（事件发生时间）—where（空间位置）”三元结构，并以 Reverse Spatio-Temporal Reasoning (RSTR) 任务组织问题链，指标上分别用 Acc（回答准确率）、m_tIoU（平均时间 IoU）与 m_vIoU（平均视觉 IoU）对三个分量做独立评估 [30]。这种拆解的价值在于：工具链即便提升了最终 QA，也可能在“找对时间”或“框对区域”上仍然失败；反过来，某些工具（如更强的时间定位器、验证器、或更密集的局部采样）可能首先体现在 m_tIoU/m_vIoU 的提升，而不是立即反映在最终文本答案上。

另一个重要方向是构造“不能靠抽帧/扫几帧取巧”的基准，以迫使系统展示真正的视频级推理与证据整合。GLIMPSE 指出现有很多视频基准在问题形态上接近图像基准，模型只需扫描少数关键帧即可作答，从而难以检验其是否真正“think with videos”[12]。为此 GLIMPSE 设计了需要观看完整视频并在全上下文上推理的问题集合：包含 3,269 个视频、4,342+ 条高度视觉中心问题，覆盖 11 类任务；在人类评测中达到 94.82% 准确率，而当前最佳模型（文中报告为 GPT-o3）仅 66.43%[12]。它还提出双向问题对（bidirectional question pairs）的计分规则：仅当一对问题两问都答对才计为正确，以降低偏置与“只对正向表述”有效的虚高表现 [12]。与之相呼应，Video-TT 也通过“主问题 + 4 个自然对抗问题”的结构来检验正确性与鲁棒性，并形式化给出鲁棒性分数

$$R = \frac{|A_{\text{full_correct}}|}{|A_{\text{primary_correct}}|}, \tag{3}$$

其报告的人机差距同样显著（人类准确率 84.3%、鲁棒性 64.3%；模型准确率 36.6%、鲁棒性 36.0%）[19]。对于工具使用研究而言，这类基准提供了一个关键检验点：工具链是否让模型在对抗改写、误导或信息分散条件下仍能稳定定位证据并维持推理一致性，而不仅是提升平均正确率。

当研究对象扩展到“以生成作为推理媒介”的 think-in-video 或视频生成推理范式时，单纯的 QA 指标也不足以覆盖“过程是否正确”。TiViBench 针对 I2V（image-to-video）生成模型构建了层次化推理基准，覆盖结构推理与搜索、空间与视觉模式推理、符号与逻辑推理、动作规划与任务执行四个维度，并在指标设计中区分了“过程-目标一致性（Process-and-Goal Consistency）”与“终态验证（Final-State Validation）”两类评测取向 [17]。它进一步引入基于跟踪与轨迹分析的度量（DINO-X tracking metrics）以评估过程一致性，并在需要事实推断的任务上使用基于 VLM 的 QA 指标补足验证能力 [17]。这表明在工具增强系统评测中，指标需要与“工具改变的对象”对齐：若工具影响的是“过程轨迹”（如连续跟踪、分步操作、逐步验证），就必须提供能刻画过程的度量，而不能只看终点输出。

在消融设置上，工具增强视频推理常见的对比维度并非“有没有工具”这么简单，而是“工具以何种粒度、在何种阶段、以何种闭环机制接入”。首先是工具集合层面的消融：在同一训练与推理框架下替换或移除某类工具，观察其对定位与最终任务的差异。在 VITAL 的工具分析中，作者比较不同视觉工具对时间定位任务的影响，指出加入 clip caption 或 clip QA 工具不仅没有提升，甚至会导致 mIoU 显著下降；相对而言，video clipping 在经验上相比其他工具更能减少幻觉 [2]。这类结果对综述写作很关键，因为它直接否定了“工具越多越好”的直觉，提示工具必须与任务信息结构、模型表征与训练信号共同适配；同时也给出了更可操作的消融写法：以同一任务（例如 temporal grounding）的 mIoU/m_tIoU 为主指标，逐个加入工具并报告增益/退化，再结合失败案例解释退化原因（冗余描述导致注意力漂移、工具输出噪声、或检索偏差放大等）。

其次是“闭环质量控制”相关消融，即验证器/一致性检查/奖励设计是否真正带来稳定性提升。VideoExplorer 在框架层面强调将 temporal grounding 与主推理链解耦，并在时间定位器中引入验证步骤：用 VLM 作为 verifier 评估检索片段是否相关，丢弃无关结果并返回验证后的证据，以缓解由无关片段引发的幻觉并让高层规划更轻量 [3]。VideoTemp-o3 则在强化学习层面指出仅用 IoU 作为奖励可能诱发“任意定位以黑客奖励”的行为，并提出 penalty-aware IoU reward 通过显式惩罚

低质量定位来缓解 reward hacking，旨在获得更稳定的多轮定位细化学习 [4]。在跨方法可比的分析中，这类机制可以被统一视作“稳定性工具”：它们不直接提供新信息，而是过滤噪声、抑制捷径、提升工具调用轨迹的可控性。因此，消融不仅应报告平均指标提升，也应报告稳定性相关统计（例如多次运行方差、失败率、或对抗扰动下的性能保持），以避免“平均提升但高不确定性”的结论被忽略。

效率指标与成本度量是 tool-using 视频推理评测中最容易被遗漏、但也是最影响落地可比性的部分。对长视频系统来说，成本往往不只是 FLOPs，还包括视觉 token 预算、离线索引/预处理开销、检索调用次数、以及多模态分支的搜索成本。VideoExplorer 直接比较不同方法的总视觉 token 使用量，强调其通过聚焦高度任务相关片段进行动态推理，在使用更少视觉 token 的同时取得更好性能 [3]；这一类“token efficiency”报告使得工具链的收益可以放在预算约束下解释，而不是只看无约束性能。

在大规模检索场景，检索成本需要进一步拆解为“检索哪些模态、每个模态的索引与查询开销、以及路由错误带来的召回损失”。ModaRoute 将“模态选择”本身工具化为 LLM 路由决策：在 ASR/OCR/视觉三类索引之间动态选择要检索的模态，并报告平均每条查询只需检索 1.78 个模态，相比穷举三模态检索降低约 41% 的计算成本，同时仍达到 Recall@5=60.9%[7]。其分析还量化了“离线 dense caption 的隐性成本与信息缺失”：dense text captions 可以达到 75.9% Recall@5，但需要昂贵的离线处理，且在 34% 的 clip 中存在 ASR 未捕获的场景文本信息 [7]。对综述而言，这里提供了一个可迁移的效率-保真折中写法：不仅报告 Recall@k，还要报告每次请求调用的模态数/检索轮次/离线预处理规模，从而让不同系统在“单位成本带来的召回提升”上可比。

与“帧数/采样密度”相关的效率指标也应被显式化，因为很多工具调用（裁剪、密采样、回看）本质上是在时间轴上重新分配感知预算。GLIMPSE 的实验观察到：随着输入帧数增加，模型准确率会先提升，但超过某个阈值后收益递减甚至下降，可能因为冗余信息过多导致模型难以聚焦有效特征 [12]。这提示在报告工具效果时，必须同时固定或报告视觉输入预算（帧数、FPS、clip 长度、分辨率等），否则“工具带来提升”可能只是“看得更多”或“看得更密”的副作用；反过来，一个好的工具应当在更低预算下达到相近或更高准确率，这也是 VideoExplorer 强调 token efficiency 的原因 [3]。

在跨方法可比的分析维度设计上，可以把“工具有效性、稳定性、效率-保真折中”三者联立，而不是分别讨论。工具有效性建议同时覆盖终局指标与过程指标：例如在 V-STaR 这类分解基准上同时报告 Acc、m_tIoU、m_vIoU，以避免工具只提升文本回答却不改善定位质量 [30]；在 VITAL 这类融合 VideoQA 与 temporal grounding 的设置中，则应以 mIoU/IoU 与 QA 指标联动分析，并通过工具消融揭示某些工具会造成 mIoU 下降这一“负迁移”现象 [2]。稳定性维度建议把“对抗一致性”和“训练/推理闭环稳定”统一到可测协议中：例如 GLIMPSE 的双向问题对计分能把语义偏置转化为可观测的准确率落差 [12]，Video-TT 的鲁棒性分数则把对抗问题的保持能力归一化到主问题正确的条件上 [19]；而训练端则可通过对 reward hacking 的显式惩罚设计来提升定位行为的可靠性与可学习性 [4]。效率-保真折中维度建议使用“性能—成本曲线”而不是单点比较：在 token/帧数/模态数等预算轴上绘制性能变化，结合如 ModaRoute 的平均检索模态数与 Recall@k[7]、以及 VideoExplorer 的视觉 token 用量对比 [3]，形成对“工具是否以更低成本换来更高保真”的直接证据。

最后，工具增强系统的评测往往跨越离线预处理与在线推理两个阶段，因此在写作中需要明确“检索成本的归属”。例如 moment sampling 的实现细节指出其 moment retrieval、开源 VideoLLM 推理在单张 A10 GPU 上运行，而闭源模型通过 API 调用并在 CPU 上推理，且帧相关性采样过程也在 CPU 上执行 [13]。这类差异意味着同一方法在不同部署条件下的瓶颈可能完全不同：GPU 成为瓶颈时应更关注视觉 token 与编码成本；API 成为瓶颈时应更关注调用次数与工具链轮数。将这

些成本以可复用的指标（例如“每题视觉 token 数”“每题工具调用次数”“每题检索模态数”“离线索引大小/构建时间”）显式化，是把“工具使用”从概念描述推进到可比实证分析的关键步骤。

12 讨论：工具边界、组合策略与开放问题

“Thinking with video”的一项核心诉求，是把原本被一次性压缩为静态上下文的视频输入，重新变成可被反复访问、可被验证的“证据工作台”。在这一语境下，“什么算工具”的边界往往比“工具能做什么”更难界定：同一项能力既可能以外部可调用的算子形式出现（如裁剪、取帧、检索与验证），也可能被吸收入端到端模型的内部策略（如隐式的采样预算分配、隐式注意力路由）。例如 Video-CoM 明确将交互步骤的动作空间限定为三个原子操作（`find-segment`、`find-frame`、`spatial-zoom`），并把推理建模为由文本与操作交织形成的多轮轨迹 τ；视频被预先等长分段，段/帧索引直接叠加在画面上，使得“调用哪个操作、参数是多少、得到什么新证据”都具有可审计接口 [5]。MedScope 进一步把这一接口规范化为由 `<think>`/`<tool_call>`/`<tool_response>`/`<answer>` 组成的结构化轨迹，并把工具空间收敛为两个“原生工具”：`crop_video`（输入时间窗，返回窗内密集采样帧序列以做局部证据获取）与 `get_frame`（输入时间戳，返回临近的三帧以做细粒度核验）[6]。在这种实现中，工具之所以被称为“工具”，并不只是因为它们执行了某种视觉运算，而是因为它们具有明确的参数化输入、可复现的可观测输出、并能作为推理链中的外显中间变量参与训练信号与评估。

与之相对，一些工作把“工具”扩展到更抽象的执行器与路由器：VideoExplorer 在框架层面把 planner、temporal grounder 与 perception 解耦，尤其强调 temporal grounder 在离线阶段把视频分段并存储为多模态嵌入，在线阶段对文本或多模态查询进行匹配，并把子查询转化为构造（construction）、检索（retrieval）、验证（verification）、总结（summarization）等动作再返回给 planner[3]。这里的“工具”不一定是单一算子，而是一个可编排的子系统：它既可以作为推理链的外部执行器降低主链复杂度，也可以引入验证器来过滤无关片段、缓解无证据的幻觉扩散 [3]。进一步地，ModaRoute 把“是否调用某个索引/模态”也视为可由 LLM 驱动的工具路由问题：其路由器（GPT-4.1）在 ASR/OCR/视觉三类索引之间做选择性查询，平均每条查询仅检索 1.78 个模态而非穷举 3.0 个模态，在维持 Recall@5=60.9% 的同时实现约 41% 的计算开销降低 [7]。从边界讨论的角度看，这类“路由—检索—融合”的决策本身并不直接改变视频内容，但它决定了后续推理链可见的证据集合，因而在系统层面与裁剪、取帧同样具有“可调用、可编排、可度量成本”的工具属性。

工具边界的另一条分界线，是“外部工具”与“内部能力/提示策略”的混杂。VITAL 这类工具增强强化学习框架，为了稳定思维与工具调用，会强制模型把交互轨迹结构化为 `<think>…</think><tool_call>{…}</tool_call>…<answer>…</answer>` 并施加严格的规则格式奖励 [2]；MedScope 同样把结构化接口纳入训练与奖励的一部分（其复合奖励包含答案正确性、格式符合性与证据对齐项）[6]。这些做法在工程上常被归入“提示/格式约束”，但它们在训练闭环中扮演的角色更接近“软工具”：它们不直接提供视觉证据，却在约束行动空间、降低行为歧义、使得验证与再检索可实施方面起到关键作用。相反，某些看似“工具化”的能力（例如“密集采样 vs 粗采样”）也可能只是模型内部的策略变量。VideoExplorer 讨论了在不同任务中对指定时间区间进行密采样（细粒度）或粗采样（全局）的动态调整，以在上下文窗口受限下平衡可扩展性与细节保真 [3]；VideoTemp-o3 也把“裁剪后密集采样”视为长视频场景下替代均匀采样不足的关键手段 [4]。当这些策略被显式为可调用模块（如 `crop_video` 的返回密集帧序列 [6]）时，它们更容易被当作工具；当它们仅以内隐的采样参数出现时，则更像模型内能力。因而，“工具”边界的可操作定义往往需要回到接口层：是否存在可独立复现的输入输出协议、是否能被单独计费/计时、是否能在轨迹上被显式评价。

在工具链组合与编排上，现有 think-with-video 系统呈现出高度一致的“粗到细（coarse-to-fine）”范式，但各工作对“粗”“细”的落点不同：有的在时间上分层，有的在证据形态上分层，有的在

模态上分层。MedScope 明确借鉴临床医生“先全局 skim 再局部回看”的流程，把证据获取组织为粗到细的时间定位与反复核验，并在工具层面给出“时间窗裁剪 → 时间戳取帧”的层级检查通道 [6]。VideoTemp-o3 把 think-with-videos 直接形式化为 `localize-crop-answer`，并支持多轮 grounding refinement：其数据构建流程中先由外部模型预测候选时间段并裁剪，再通过闭环一致性验证保留样本；对长视频（>3 min）才允许额外一轮 refinement，从而形成 multi-tool-call 训练数据 [4]。Video-CoM 则把粗到细落在“从段到帧到空间区域”的操作层级：先 `find-segment` 回看短 clip，再 `find-frame` 冻结关键帧，最后 `spatial-zoom` 裁剪放大以读出细节 [5]。这类层级编排的共同点在于把高成本的高分辨率感知延后到“已知值得看”的局部区域，减少把长视频全部高密度编码带来的 token 与计算浪费；VideoExplorer 的 token 效率分析也体现了这一点：通过聚焦高相关片段实现“更少视觉 token 但更好性能”[3]。

“检索—验证—再检索”是另一类常见编排，它把工具链从“取证”扩展到“证据可靠性控制”。VideoExplorer 的 temporal grounder 在返回片段前引入 VLM verifier 来判断检索片段是否相关，不相关则丢弃，以避免无关片段进入主推理链造成幻觉 [3]。VideoTemp-o3 的闭环一致性验证（只保留答案与 ground-truth 一致的样本）把验证前移到数据构建阶段，通过训练数据筛选为多轮工具调用提供更稳定的监督 [4]；MedScope 在数据侧同样引入跨模型过滤与“multimodal confirmation”，要求直接从裁剪片段 $\mathrm{Clip}(V, w)$ 回答，以排除 caption 幻觉与知识捷径，从而确保样本确实由局部视频证据支撑 [6]。这些设计暗示了一个重要组合原则：在长视频任务中，工具调用的收益并不只来自“看到更多”，而是来自“看到且能证明自己看到的是对的”。当验证环节缺失时，工具链可能把噪声证据更高分辨率地放大，从而加速推理漂移。

然而，工具链并非“越多越好”，而且错误往往以非线性的方式放大。VITAL 的工具消融显示：在时序定位任务中加入 clip caption 或 clip QA 工具不仅无益，甚至会导致 mIoU 出现显著下降；而 video clipping 相较其他工具在经验上更能降低幻觉 [2]。这一结果提示工具链组合存在强任务依赖与强交互项：某些工具在独立评估中看似“提供信息”，但在端到端闭环中可能引入冗余与噪声、或改变模型的注意力分配方式，从而伤害定位精度。GLIMPSE 的分析从评测侧给出了相似信号：随着输入帧数增加，模型准确率先提升、超过某个阈值后收益递减甚至下降，作者将其归因于冗余信息与难以聚焦相关特征 [12]。这在工具视角下意味着：无论是“多看帧”还是“多调用工具”，都需要有路由与压缩机制来对抗冗余，而不能将信息量当作单调的性能杠杆。

泛化与迁移问题在 think-with-video 场景尤为突出，因为工具链把“任务解决方案”显式绑定在特定接口、索引与数据分布上。首先，跨时长的迁移仍未被充分覆盖：GLIMPSE 将视频长度限制在 20 秒到 2 分钟以满足其任务设计与标注边界 [12]，而 Video-VER 的局限性也指出其主要研究对象是“moderate length”的视频，并将非常长视频（尤其关键证据稀疏或时间模式复杂）作为未来方向 [10]。这意味着许多在中短视频上有效的工具编排（例如一次裁剪或一次检索）在超长视频上可能因证据稀疏而失效，需要更强的“多轮检索与证据记忆”。其次，跨领域迁移会暴露工具定义与误差模型的差异：MedScope 明确面向临床长视频，并强调其潜在收益与部署风险，指出不应作为独立临床使用、需要鲁棒性评估与人类监督 [6]。在此类高风险领域中，工具调用不仅要“找得到证据”，还要能够表达不确定性与失败模式；而许多通用领域的工具链（如基于 IoU 的定位奖励、基于选择题的自动评测）在医学领域可能带来不同的误判成本。

数据与可复现性构成了当前工具使用研究的系统性瓶颈。一方面，多步工具轨迹往往依赖强大的外部闭源模型生成或筛选：Video-CoM 用 Gemini-2.5-Pro 生成每个视频 3–5 个 QA（总计 25K），经验证后保留约 75% 得到 18K，高质量数据中 15K 用于 SFT、3K 用于 GRPO，并且 RL 部分还额外策划 70 个 YouTube 多上下文视频 [5]；VideoTemp-o3 亦在数据构建中使用 Gemini-2.5-Pro 预测候选时间段与多轮 refinement，并用闭环一致性验证筛选样本 [4]；ModaRoute 的路由组件依赖 GPT-4.1[7]；VideoExplorer 则指出由于缺乏高质量推理导向训练数据，借助强 LLM 结合其框架生

成推理数据，并以“仅保留正确答案轨迹”的方式确保有效性，最终整理 11.1k planner trajectories 与 10.8k grounding trajectories[3]。这些做法在短期内提高了数据质量与系统能力，但也带来两类复现风险：其一是闭源模型与提示词不可控导致的数据分布难以复刻；其二是“只保留正确轨迹”的筛选策略可能引入系统性的选择偏差，使训练数据更接近外部教师模型的能力边界而非真实任务分布 [3]。另一方面，即便使用开源外部模型，数据生成也可能引入隐性偏差：Video-VER 在训练阶段用 Qwen2.5-VL-72B 生成问题相关视觉证据，但测试时策略模型独立运行、不依赖外部模型 [10]。这种“训练期工具、推理期不用”的设计有助于部署效率与接口简化，却要求研究者更清楚地报告证据生成器的配置、提示与失败率，否则难以判断性能提升来自证据对齐本身还是来自教师模型的偏置迁移。

鲁棒性风险往往来自工具链中的“中间决策点”，尤其是验证器与路由器的误判。VideoExplorer 依赖 verifier 判断片段相关性并丢弃无关结果，这确实能缓解无关片段引发的幻觉，但同时也引入“证据遗漏”的新风险：一旦 verifier 误过滤关键片段，planner 将在缺证据情况下继续推理并可能产生高置信错误 [3]。ModaRoute 的误差分析揭示了另一种系统性脆弱性：OCR 查询的路由准确率仅 42.9%，且主要错误来自字幕导致的 ASR/OCR 混淆、以及视觉描述与文本线索的重叠，使得路由器呈现“遗漏 OCR 的保守偏置”[7]。对视频推理而言，这类偏置意味着某些证据类型会在工具链入口处被系统性屏蔽，后续再复杂的推理与验证也无法弥补。与之相关，Video-VER 的失败案例指出“不完整的帧采样”会遗漏关键视觉上下文 [10]，而 GLIMPSE 的实验则显示“帧过多”也可能因冗余而削弱聚焦能力 [12]。两者共同指向一个鲁棒性悖论：采样过少会漏证据，采样过多会淹没证据；真正稳定的系统需要把采样本身变成可学习、可解释、可验证的工具策略，而不仅是固定超参数。

强化学习与奖励设计在工具使用研究中同时扮演“推动器”与“风险源”。VideoTemp-o3 明确指出仅用 IoU 作为定位奖励会诱发 reward hacking（模型可能任意定位以套利），因此提出 penalty-aware IoU reward 以惩罚低质量定位行为并鼓励稳定的多轮细化 [4]；VITAL 同样观察到多任务 RL 中存在 task-wise 与 sample-wise 的难度不均衡，并通过 difficulty-aware 的方法缓解训练偏置，同时用格式奖励稳定工具调用 [2]；MedScope 将工具证据对齐纳入复合奖励（对 `crop_video` 用 temporal overlap/IoU，对 `get_frame` 用时间戳对齐），并与格式检查共同约束策略空间 [6]。这些工作共同说明：工具调用并不天然等价于“获取更好证据”，而需要通过奖励与约束把“调用是否正确”“证据是否对齐”“是否存在投机路径”显式化。与此同时，奖励的可计算性往往迫使研究者选择易度量但可能偏狭的代理指标（如 IoU、时间戳误差），这又会反过来塑造模型偏好并带来新的泛化缺口。

面向未来的工具方向，现有证据表明最值得系统化研究的并非单一算子的“更强版本”，而是围绕证据生命周期的工具化基础设施：其一是更强的“信息路由与预算调度”工具，把 GLIMPSE 所揭示的“冗余导致性能下降”现象转化为可学习的选择机制，并与像 ModaRoute 这样的模态路由结合，实现跨模态、跨时长的证据分配 [12, 7]。其二是“可验证证据表示”的标准化，把 Video-VER 提出的“问题相关视觉证据”从训练期奖励信号推广为可共享的中间表示，使工具链不仅返回片段/帧，还返回结构化观察与可检查的支持理由，从而缓解 VideoExplorer 所面临的 verifier 误判与证据遗漏风险 [3, 10]。其三是“工具链失效诊断与反事实验证”：在 VITAL 已观察到某些工具会显著降低 mIoU 的情况下，仅靠平均性能难以解释工具为何伤害，迫切需要能定位是“路由错误、验证误判、采样冗余还是索引偏差”导致的失败剖析框架 [2]。最后，数据与复现层面需要更透明的轨迹生成与筛选协议：当多项工作都依赖 Gemini-2.5-Pro、GPT-4.1 等外部模型生成或路由时，若缺少可替代的开源教师与标准化提示，工具使用研究将难以形成可累积的比较基线与可验证的结论 [4, 5, 7]。

13 结论

本文围绕“think with video”范式中的工具使用（tool using）追问：除局部区域放大（zooming）与拆帧/抽帧等“按帧访问”之外，人类（以及受人类启发的系统设计者）还发明了哪些可复用的视频操作工具与调用机制。综合代表性框架可以看到，工具并不局限于对像素输入做局部变换，而是扩展为一套“按需取证—可验证对齐—再取证”的交互式感知闭环：一方面将时间轴上的检索、定位、裁剪与重看显式化；另一方面将跨模态信息抽取、证据过滤/验证、对象级持续指代与运动表征等能力外部化为可调用组件，并通过结构化轨迹与奖励对齐把这些组件稳定纳入推理过程 [3, 5, 4]。

在“除拆帧以外”的时间维度工具上，最具共性也最直接的增量来自对时间轴的可操作化：不是简单抽取均匀帧序列，而是让模型能够选择“看哪一段、看多长、是否回看、是否细化”。Video-CoM 将交互动作显式离散化为 find-segment（按段回看短时间窗）、find-frame（按索引取高分辨率关键帧）与 spatial-zoom，并把推理表述为多轮轨迹 $\tau = \{(T_i, V_i, m_i)\}_{i=1}^{N}$ 的循环，强调“回看/重访”作为与拆帧不同的时间操作原语 [5]。VideoTemp-o3 更进一步把任务形式化为 localize–crop–answer：模型先定位候选时间区间，再执行裁剪（cropping）与密集采样（dense sampling）取证，并允许多轮 grounding refinement；其数据构建还明确只对长视频（$> 3\,\text{min}$）启用额外细化回合，以体现“越长越需要迭代式工具调用”的现实约束 [4]。类似地，MedScope 在临床长视频中把“粗到细”的层级检索固化为两个原生工具：crop_video 输入时间窗返回该窗内密集采样的帧序列以收集局部证据，get_frame 输入时间戳返回最邻近的三帧以做细粒度核验，从接口层面把“裁剪—密看—核验”的临床工作流转写为可学习的动作空间 [6]。

与时间定位工具并行演化的是“感知预算调度”这一更接近系统层的工具机制：同样是取帧，关键不在是否拆帧，而在于由推理过程动态决定采样密度与覆盖范围，从而在窗口受限下同时保留全局可扩展性与局部保真度。VideoExplorer 将这一点清晰地制度化：规划器提出子问题后，时间定位器在离线分段嵌入库中检索候选区间并调用验证器过滤，再由视频理解模块按任务选择粗采样或密采样；论文同时以视觉 token 用量对比说明，相比“无差别处理全部片段”的策略，其聚焦高度相关片段的按需访问能够在更少视觉 token 下取得更好性能，因而“采样粒度”本身成为可调度的工具参数而非固定的预处理策略 [3]。

除“去哪看/怎么看”之外，think-with-video 工具谱系的另一条主线是“如何确保看过的东西真的支撑了推理”。这类工具不一定直接改动视频，而是把证据核验与幻觉抑制外显为可调用的验证/评价模块，或把证据对齐转化为可优化的奖励信号。VideoExplorer 的 temporal grounder 在检索后用 VLM 作为 verifier 判定片段相关性，丢弃无关片段并仅返回经验证的证据，从而把“检索—验证—回传”从主推理链中解耦出来以降低漂移与幻觉风险 [3]。VideoTemp-o3 的训练数据流水线包含 closed-loop consistency verification：只有当裁剪片段条件下的答案与 ground-truth 保持一致时样本才被保留，用数据筛选把“片段足以支持答案”的证据充足性变成硬约束 [4]。在训练信号层面，MedScope 以复合奖励 $R = R_{acc} + R_{format} + R_{evidence}$ 将证据对齐显式纳入强化学习目标，其中 $R_{evidence}$ 通过时间重叠（对 crop_video）与时间戳对齐（对 get_frame）衡量 grounding 质量，使模型在“答对”之外还必须“用对工具、对齐证据”[6]；VideoTemp-o3 亦指出仅用 IoU 奖励会诱发 reward hacking，并通过 penalty-aware IoU reward 对低质量定位行为施加惩罚以稳定多轮细化学习 [4]。当研究视角从“如何调用工具”转向“如何让推理不漂移”时，工具甚至可以仅在训练期出现：Video-VER 用外部强 MLLM（Qwen2.5-VL-72B）离线生成问题相关的 visual evidence，并以 Visual Evidence Reward（VER）奖励“推理轨迹可验证地扎根于视觉证据”，而策略模型在测试时独立推理、不依赖外部证据生成器；其在 10 个公开基准上 9/10 项排名第一的结果，实质上凸显了“证据对齐评价”作为工具/奖励的价值 [10]。此外，VITAL 的工具消融也提醒：工具并非越多越好，在其时序定位任务上加入 clip caption 或 clip QA 反而会导致 mIoU 显著下降，而 video

clipping（按预测区间裁剪并只在片段上回答）经验上更能降低幻觉，说明工具的收益高度依赖任务设定与工具-模型的协同优化方式 [2]。

从更宽的“工具”定义看，跨模态辅助工具构成了除 zoom/拆帧之外最常被忽略却最具工程决定性的类别：ASR、OCR、字幕/描述生成与跨文档对齐等，把视频中的“可检索符号”提取出来并转化为可索引材料。ModaRoute 将该方向推进为显式的“路由工具”：用 GPT-4.1 预测查询所需模态，在 ASR/OCR/视觉三类索引间做选择性检索，平均每次仅查询 1.78 个模态而非穷举 3.0 个模态，在保持 Recall@5=60.9% 的同时将计算成本降低约 41%；其误差分析显示 OCR 路由准确率仅 42.9%，且存在字幕导致 ASR/OCR 混淆与 OCR-视觉语义重叠等系统性失败模式，直接指向后续 tool using 研究中“何时触发 OCR、如何校验 OCR 需求”的关键缺口 [7]。MaVi LS 则把“视频—幻灯片对齐”作为另一种结构化索引工具：通过语音转写（faster-whisper/Whisper）、OCR（Tesseract）与图像特征融合，并用动态规划求解最优幻灯片序列；在约 22 小时、12,830 段的视频数据上，其融合方法平均准确率 0.82，相比 SIFT 基线 0.56 且约快 11 倍，并给出了不同模态特征计算的分钟级开销分解（如文本特征平均约 3 分钟）以刻画工具链的真实成本 [8]。面向 OCR 本身的能力瓶颈，VideoOCRBench 进一步将“读文字”“检索文字出现时刻”“基于文字问答”三类任务基准化，并指出在小文本、移动与运动模糊条件下 VLM 性能显著下降、易出现字符幻觉或对短暂文本漏检，提示在 think-with-video 系统中把 OCR 作为工具并不足够，还需要与时间定位、稳像/去模糊、文本区域定位等配套操作共同组成可用的证据获取链路 [9]。

最后，一类常被误归为“模型能力”而非“工具”的机制，是对象级持续指代与运动证据提取。对于需要跨帧追踪同一对象、验证动作连续性或建立因果链的任务，单次拆帧并不能解决“身份一致性”与“跨时刻关联”问题。TAD（Tracking Anything with Decoupled Video Segmentation）将视频目标跟踪解耦为逐帧分割与身份传播：逐帧分割可直接复用强图像分割基础模型生成掩膜，再用 mask IoU 与外观嵌入做跨帧关联以维持 identity；这种“可插拔的逐帧感知器 + 轻量时序关联器”的工具化结构，为 think-with-video 系统提供了稳定的对象级记忆与指代接口 [21]。Two-shot VOS 的双向传播与融合策略则展示了另一种时间工具：在仅有首末帧标注的弱监督条件下，通过前向与后向两路传播并对中间帧融合，使“从两端约束中间过程”的时序推断成为可复用操作序列，尤其适合长视频中目标外观大幅变化或消失再出现的情形 [25]。在运动表征方面，相位（phase）作为光流的替代也可被视作“运动证据工具”：相位变化可表征运动而无需显式估计速度；同时，该工作在实验设置中将“时间导数（如灰度帧时间导数堆叠）”作为输入特征之一，用以在较低开销下捕捉变化并辅助动作识别 [22]。关于“RGB 差分替代光流”“具体加速倍数”等更强的量化结论，现有正文所引来源在公开信息中主要聚焦相位表征本身，因而此处不再给出具体倍率描述，以避免不同工作结论被误并置造成的证据错配风险。

因此，对研究问题的回答是肯定的：除 zooming 与拆帧外，tool using 的主要增量并不来自更多低层视觉变换，而来自把“时间轴可操作化、证据可验证化、跨模态可索引化、对象与运动可持续化”四类机制系统化，并让规划/路由在这些机制之上进行多轮编排 [3, 6, 7]。与此同时，多项工作揭示了一个共同的反直觉观察：工具的引入可能带来性能下降或新的失败模式，尤其当工具输出与任务奖励/评测口径未对齐时（例如工具增加了文本中间层却削弱了时序定位 mIoU，或路由遗漏 OCR 导致关键屏幕文本缺失）[2, 7]。这意味着 think-with-video 的核心挑战正在从“能不能调用工具”转向“能否在有限预算下选择正确工具、并用可审计的证据链证明工具调用的必要性与充分性”。

面向后续研究路线，首先需要把工具调用的评价从最终答案扩展为“轨迹级可比性”：一方面沿用并推广结构化接口与格式奖励，使不同系统输出的工具调用（tool call）与观测（observation）可被统一解析与自动评分（如 MedScope 的 `<think>/<tool_call>/<tool_response>/<answer>` 轨迹接口，以及 VITAL 的严格格式奖励以稳定 rollouts）[6, 2]；另一方面，需要将中间步骤的正确性与证据覆盖纳入指标体系，避免只优化终局准确率导致路径漂移或 reward hacking（Video-CoM

的 step-level reasoning reward、VideoTemp-o3 的惩罚感知 IoU、Video-VER 的证据奖励均指向这一方向）[5, 4, 10]。其次，基准与数据应更系统地覆盖“工具触发条件”而非仅覆盖“工具执行结果”：例如在包含屏幕文字的长视频中，需要同时标注“何时必须 OCR/何时仅视觉足够”的需求标签，并显式纳入对路由错误（漏选 OCR、混淆字幕）的惩罚，从而把 ModaRoute 揭示的失败模式转化为可训练的监督信号 [7]；在长视频时间定位任务中，则应提供可验证的多轮细化轨迹与否定样本（错误定位但答案正确/正确定位但答案错误），以支持对“证据充分性”的更严格评测 [4]。再次，效率指标需要与工具链共同定义：不仅报告准确率或 mIoU，还应同时报告视觉 token、检索/索引成本与端到端运行时（如 ModaRoute 的模态数、MaViLS 的分钟级开销分解、VideoExplorer 的视觉 token 对比），否则不同工具组合之间难以形成可复用的设计结论 [7, 8, 3]。

总之，think-with-video 的工具谱系已经从“看得更清楚”（zoom/拆帧）演进到“看得更对、更省、更可核验”：时间区间检索/裁剪与多轮细化、粗到细的采样调度、证据验证与奖励对齐、跨模态符号抽取与路由、对象级跟踪/分割与运动表征等，构成了除 zooming 与拆帧之外的主要工具类别与机制 [3, 4, 6, 7, 21]。未来更具决定性的突破，可能来自将这些工具在统一接口下组织为可迁移的“证据操作语言”，并用轨迹级数据与指标让不同工具链的收益与代价可重复、可比较、可诊断。

参考文献

[1] Thinking with Video: Video Generation as a Promising Multimodal Reasoning Paradigm. https://arxiv.org/abs/2511.04570v1

[2] Thinking With Videos: Multimodal Tool-Augmented Reinforcement Learning for Long Video Reasoning. https://arxiv.org/abs/2508.04416v2

[3] VideoExplorer: Think With Videos For Agentic Long-Video Understanding. https://arxiv.org/abs/2506.10821v6

[4] VideoTemp-o3: Harmonizing Temporal Grounding and Video Understanding in Agentic Thinking-with-Videos. https://arxiv.org/abs/2602.07801v2

[5] Video-CoM: Interactive Video Reasoning via Chain of Manipulations. https://arxiv.org/abs/2511.23477v1

[6] MedScope: Incentivizing ”Think with Videos” for Clinical Reasoning via Coarse-to-Fine Tool Calling. https://arxiv.org/abs/2602.13332v1

[7] Smart Routing for Multimodal Video Retrieval: When to Search What. https://arxiv.org/abs/2507.13374v1

[8] MaViLS, a Benchmark Dataset for Video-to-Slide Alignment, Assessing Baseline Accuracy with a Multimodal Alignment Algorithm Leveraging Speech, OCR, and Visual Features. https://arxiv.org/abs/2409.16765v1

[9] Benchmarking Vision-Language Models on Optical Character Recognition in Dynamic Video Environments. https://arxiv.org/abs/2502.06445v1

[10] When Thinking Drifts: Evidential Grounding for Robust Video Reasoning. https://arxiv.org/abs/2510.06077v1

[11] Video-Thinker: Sparking "Thinking with Videos" via Reinforcement Learning.https://arxiv.org/abs/2510.23473v1.

[12] GLIMPSE: Do Large Vision-Language Models Truly Think With Videos or Just Glimpse at Them?https://arxiv.org/abs/2507.09491v1.

[13] Moment Sampling in Video LLMs for Long-Form Video QA.https://arxiv.org/abs/2507.00033v1.

[14] Video Understanding with Large Language Models: A Survey. https://arxiv.org/abs/2312.17432v8

[15] Video-LLaMA: An Instruction-tuned Audio-Visual Language Model for Video Understanding. https://arxiv.org/abs/2306.02858v4

[16] Prompting Video-Language Foundation Models with Domain-specific Fine-grained Heuristics for Video Question Answering. https://arxiv.org/abs/2410.09380v1

[17] TiViBench: Benchmarking Think-in-Video Reasoning for Video Generative Models. https://arxiv.org/abs/2511.13704v2

[18] *THaMES: An End-to-End Tool for Hallucination Mitigation and Evaluation in Large Language Models*. Available at: https://arxiv.org/abs/2409.11353v3.

[19] Towards Video Thinking Test: A Holistic Benchmark for Advanced Video Reasoning and Understanding.https://arxiv.org/abs/2507.15028v1

[20] Language as the Medium: Multimodal Video Classification through text only.https://arxiv.org/abs/2309.10783v1

[21] Tracking Anything with Decoupled Video Segmentation. https://arxiv.org/abs/2309.03903v1.

[22] Using phase instead of optical flow for action recognition. https://arxiv.org/abs/1809.03258v2.

[23] SegFlow: Joint Learning for Video Object Segmentation and Optical Flow. https://arxiv.org/abs/1709.06750v1.

[24] Every Frame Counts: Joint Learning of Video Segmentation and Optical Flow.https://arxiv.org/abs/1911.12739v1.

[25] Two-shot Video Object Segmentation.https://arxiv.org/abs/2303.12078v1.

[26] Video Object Segmentation with Re-identification.https://arxiv.org/abs/1708.00197v1.

[27] Weakly Supervised Convolutional LSTM Approach for Tool Tracking in Laparoscopic Videos. https://arxiv.org/abs/1812.01366v2.

[28] SurgiTrack: Fine-Grained Multi-Class Multi-Tool Tracking in Surgical Videos.https://arxiv.org/abs/2405.20333v3.

[29] Video Language Planning. https://arxiv.org/abs/2310.10625v1.

[30] V-STaR: Benchmarking Video-LLMs on Video Spatio-Temporal Reasoning. https://arxiv.org/abs/2503.11495v1.